



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey.

**Inteligencia Artificial Avanzada para la Ciencia de Datos
“Reto CAETEC | Business Understanding”**

Profesores:

**Benjamín Valdés Aguirre
Eduardo Daniel Juárez Pineda**

Jorge Armando Garzón Varela | A01707102
Santiago Alducin Villaseñor | A01707122
Sebastián Pérez García | A01707346
Roberto Serna Niño | A01709577
Kamila Jeannette Martinez Ibarra | A01711833

Fecha de entrega: 07 de octubre de 2025

Índice

1. Objetivo de Negocio

- 1.1 Antecedentes
- 1.2 Objetivo de Negocio
- 1.3 Criterios de Éxito

2. Evaluación de la Situación

- 2.1 Inventario de Recursos
- 2.2 Requerimientos, Supuestos y Restricciones
- 2.3 Riesgos y Contingencias
- 2.4 Terminología
- 2.5 Costos y Beneficios

3. Objetivos de Minería de Datos

- 3.1 Objetivo 1
- 3.2 Objetivo 2
- 3.3 Objetivo 3

4. Plan del Proyecto

- 4.1 Work Breakdown Structure (WBS)
- 4.2 Plan de Valor Ganado (PVG)
- 4.3 Evaluación de Herramientas y Técnicas

1. Objetivo de Negocio

En esta sección se presenta el contexto general del proyecto y del funcionamiento del CAETEC, con el propósito de comprender la situación que da origen al análisis de las colas en el sistema de ordeño automático. Asimismo, se define el objetivo de negocio, las preguntas que guiarán el análisis y los criterios que permitirán evaluar el éxito del proyecto.

Para esta etapa se siguieron los entregables establecidos por la metodología CRISP-DM, por lo que no fue necesario realizar adaptaciones a los entregables correspondientes a esta sección.

1.1 Antecedentes

El CAETEC es un rancho y laboratorio experimental del Tecnológico de Monterrey, ubicado en el municipio de Pedro Escobedo, Querétaro. En él se realizan diferentes actividades y experimentos relacionados con la producción y el comportamiento del ganado. Además de funcionar como un rancho de producción, sus instalaciones permiten estudiar el comportamiento de las vacas y evaluar diversas prácticas y tecnologías aplicadas a su manejo.

Actualmente, el CAETEC cuenta con aproximadamente 148 vacas, distribuidas en diferentes corrales con alrededor de 25 a 30 vacas por corral. Para la producción de leche se utiliza un Sistema de Ordeño Voluntaria (VMS), el cual funciona de manera automática y permite que las vacas acudan a ordeñarse por cuenta propia, sin depender de un horario fijo. Este sistema busca adaptarse a las necesidades individuales de cada vaca y facilitar el proceso de ordeño.

Dentro de su rutina diaria, las vacas suelen alternar principalmente entre tres actividades distintas: ser ordeñadas, alimentarse y descansar. El alimento se sirve dos veces al día, aproximadamente a las 7:30 y 14:30 horas. Fuera de estos momentos, las vacas cuentan con libertad para decidir cuándo comer, descansar o acudir nuevamente al sistema de ordeño.

Las vacas se encuentran distribuidas principalmente en corrales de producción de leche, además de un corral destinado a aquellas que requieren mayor atención o manejo. Dentro de los grupos también existe una jerarquía social relacionada con el carácter y la experiencia de cada vaca. Algunas pueden ejercer mayor influencia sobre las demás e incluso adelantarse o desplazar a otras en la fila para la ordeña. Por otro lado, las vacas con un carácter más tranquilo o con menor experiencia, especialmente aquellas de primer parto, pueden permanecer más tiempo esperando y deben adaptarse al comportamiento del resto del grupo.

La producción de leche de una vaca pasa por diferentes etapas a lo largo de su ciclo de lactancia. Durante los primeros días después del parto se encuentran las denominadas vacas frescas, cuya producción aumenta progresivamente hasta acercarse a su punto máximo. Esta primera etapa tiene una duración aproximada de 100 días. Posteriormente, la vaca pasa por un periodo de alta producción, también cercano a los 100 días, en el que comienza un ligero descenso. Finalmente, entra en una etapa de menor producción hasta completar aproximadamente 305 días de lactancia. Después de completar este lapso, se presenta un periodo de secado y recuperación de alrededor de 60 días antes de comenzar un nuevo ciclo.

El CAETEC produce aproximadamente 6,000 litros de leche al día. Para el funcionamiento de este sistema, las actividades de mayor importancia para las vacas son la ordeña, la alimentación y el descanso, ya que están directamente relacionadas con su producción. Bajo este contexto, el tiempo que una vaca permanece en la cola para acceder al VMS se considera tiempo no productivo. Cuando las esperas se prolongan demasiado, se reduce el tiempo disponible para otras actividades importantes, principalmente la alimentación y el descanso, además de generar posibles afectaciones en el bienestar y en la producción de las vacas.

Por esta razón, resulta relevante comprender cuándo se presentan colas prolongadas y bajo qué condiciones tienden a formarse las mismas. A partir de ello, se busca reconocer patrones dentro del funcionamiento del sistema que permitan comprender mejor este fenómeno y que puedan servir como apoyo en la mejora del manejo de las vacas y el proceso de ordeña.

1.2 Objetivo de Negocio

El objetivo principal del proyecto es: **Identificar patrones temporales y condiciones recurrentes asociados con la formación de colas en el sistema de ordeño automático.**

Con esto se busca comprender cuándo y bajo qué circunstancias se presentan periodos prolongados de espera, de manera que la información obtenida pueda generar información relevante relacionada con el manejo de las vacas y el funcionamiento del proceso de ordeño.

A partir de este objetivo, se plantean las siguientes preguntas de negocio:

- ¿En qué horas y días se presentan las colas y cuánto tiempo suelen durar?
- ¿Cómo se distribuye el tiempo entre la espera y el ordeño de las vacas?
- ¿Existen momentos en los que el patrón de colas haya cambiado notablemente?
- ¿Cuál es la duración habitual de las colas en cada VMS y qué tan variable es?
- ¿Qué patrones de las colas tienden a repetirse entre distintos días?

1.3 Criterios de Éxito

El éxito del proyecto se determinará a partir de la capacidad del análisis para encontrar patrones y comportamientos relevantes relacionados con la formación y duración de las colas en el sistema de ordeño automático. Los hallazgos obtenidos deberán aportar información útil para describir y comprender mejor las condiciones bajo las cuales se presenta este fenómeno.

Se establecen los siguientes criterios de éxito:

- Encontrar un patrón que permita identificar sucesos atípicos que detengan la cola.
- Identificar características de las vacas con mayor probabilidad de detener una cola.
- Encontrar tendencias o similitudes entre las colas a lo largo de diferentes días.

Debido a la naturaleza del proyecto, el socio formador determinará si los patrones y hallazgos identificados son suficientemente relevantes y útiles para mejorar la comprensión de las colas.

2. Evaluación de la Situación

En esta sección se presenta una evaluación de la situación actual del proyecto, considerando los recursos disponibles, los requerimientos, supuestos y restricciones, así como los posibles riesgos y contingencias. También se establece la terminología utilizada a lo largo del proyecto y se analizan los costos y beneficios potenciales relacionados con el desarrollo del mismo.

Para esta etapa se siguieron los entregables establecidos por la metodología CRISP-DM, por lo que no fue necesario realizar adaptaciones a los entregables correspondientes a esta sección.

2.1 Inventario de Recursos

Para el desarrollo del proyecto se realizó un inventario de los recursos disponibles, considerando tanto los recursos humanos como el hardware y software al que tiene acceso el equipo. En este se incluyen los integrantes del equipo de desarrollo, expertos y socios que pueden brindar apoyo durante el proyecto, así como los equipos de cómputo y las herramientas de software disponibles para el análisis, procesamiento y modelado de los datos.

El inventario completo de los recursos disponibles para el proyecto puede consultarse [aquí](#).

2.2 Requerimientos, Supuestos y Restricciones

Calendario de Entrega

El calendario de entregas presenta la planificación de las principales etapas y entregables que conforman el proyecto, indicando las fechas estimadas de inicio y finalización de cada actividad. Este calendario permite organizar el desarrollo del proyecto de acuerdo con las fases de CRISP-DM y dar seguimiento al cumplimiento de los entregables establecidos.

El calendario completo, incluyendo fechas planeadas de cada entrega, puede consultarse [aquí](#).

Comprensibilidad de los Datos

Para facilitar la comprensión de los datos proporcionados por el CAETEC, se realizó una descripción inicial de las principales variables disponibles en los registros del sistema de ordeño. Para cada variable se identificó su significado dentro del contexto del proyecto, su unidad o formato y una breve explicación de la información que representa la misma.

La tabla con las variables disponibles, sus unidades y descripción puede consultarse [aquí](#).

Seguridad

Para garantizar un manejo adecuado de la información a utilizar durante el proyecto, se establecieron las siguientes consideraciones de seguridad, acceso y manejo de los datos:

Almacenamiento y acceso: La información del proyecto será almacenada principalmente en Google Drive, dentro de una carpeta privada con acceso limitado a los integrantes del equipo. Esto permite mantener control sobre las personas que pueden consultar o manipular los datos.

Datos personales: Los datos proporcionados para el proyecto no contienen información personal ni sensible de los colaboradores o miembros del rancho. Por lo tanto, no es necesario contemplar el tratamiento de datos personales y/o sensibles ni la aplicación de derechos ARCO (Acceso, Rectificación, Cancelación y Oposición) dentro del alcance del proyecto.

Aspectos Legales

Para el desarrollo del proyecto se consideran los aspectos legales relacionados con la protección, tratamiento y confidencialidad de la información proporcionada por el CAETEC.

Debido a la naturaleza académica y de investigación del proyecto, el equipo cuenta con la autorización del CAETEC para utilizar los datos proporcionados únicamente para los fines establecidos en el proyecto. Esta autorización no permite divulgar o hacer pública la información ni compartirla con personas externas al equipo de trabajo, por lo que los datos deberán mantenerse cuidadosamente bajo un acceso restringido durante su desarrollo.

Supuestos del Proyecto

Para el desarrollo del proyecto se parte de una serie de supuestos relacionados con los datos disponibles y el funcionamiento del CAETEC. Respecto a los datos, se considera que existe un mayor uso del sistema de ordeño durante el día que durante la noche y que cada archivo proporcionado corresponde a la producción de leche de una vaca en particular. Asimismo, se asume que se cuenta con información suficiente sobre la producción de leche, los tiempos relacionados con el proceso de ordeño y los registros correspondientes a cada pezón.

En cuanto al contexto del negocio, se considera que las vacas son alimentadas dos veces al día, que sus actividades incluyen alimentación, descanso y ordeño, y que tienen la posibilidad de acudir voluntariamente al sistema de ordeño en cualquier momento, con excepción de aquellos periodos en los que la máquina se encuentre en mantenimiento o no esté disponible.

Restricciones del Proyecto

Una de las principales restricciones del proyecto está relacionada con la disponibilidad y obtención de los datos. El CAETEC cuenta con disponibilidad limitada para atender solicitudes adicionales de información, por lo que obtener nuevos datos puede requerir comunicación previa, la programación de una visita, e incluso acudir físicamente al rancho.

También existen restricciones relacionadas con los recursos técnicos disponibles. La capacidad de procesamiento y memoria varía de acuerdo con el equipo de cómputo de cada integrante, lo que puede limitar algunos análisis que requieran una mayor cantidad de recursos. Como alternativa se cuenta con Google Colab, que permite acceder a mayores recursos computacionales, aunque presenta limitaciones de tiempo y disponibilidad de uso.

2.3 Riesgos y Contingencias

Para el desarrollo del proyecto se identificaron distintos riesgos relacionados con los datos, el contexto de negocio y la disponibilidad de información, los cuales podrían afectar el análisis o la interpretación de los resultados. Para cada riesgo se evaluó su impacto, además de definir planes de mitigación y de contingencia para reducir sus posibles efectos sobre el proyecto.

La matriz de riesgos del proyecto, junto con su clasificación, evaluación de probabilidad e impacto, así como estrategias de mitigación y planes de contingencia, puede consultarse [aquí](#).

2.4 Terminología

En esta sección se definen los principales términos utilizados a lo largo del proyecto con el propósito de establecer un lenguaje común y facilitar la comprensión del análisis. La terminología se divide en dos categorías: términos del negocio, relacionados con el proceso de ordeño, y términos técnicos, relacionados con la minería de datos y herramientas a utilizar.

Terminología del Negocio:

- **CAETEC:** Campo Agrícola Experimental del Tecnológico Monterrey, campus Querétaro. La cual cuenta con un hato lechero y un sistema de ordeño automatizado.
- **VMS (Voluntary Milking System):** Sistema de ordeño robotizado en donde las vacas siguen de manera voluntaria al robot para ser ordeñadas, sin ningún horario específico establecido por el personal.
- **Ordeño:** Es el proceso en donde la leche de las vacas es extraída de las glándulas mamarias

- **Duración del ordeño:** Es el tiempo total que tarda una sesión de ordeño, el cual es tomado desde el tiempo de entrada hasta salida.
- **Idling time:** Tiempo en donde el robot está disponible para ordeñar, sin embargo no está siendo utilizado.
- **Utilización del VMS:** Es la proporción del tiempo en la que el robot está ocupado ordenado en respecto al tiempo disponible
- **Franja horaria:** Intervalo del día
- **Intervalo entre ordeños:** Tiempo que pasa entre dos ordeños para la misma vaca.
- **Producción de leche:** Cantidad de leche obtenida en un ordeño, en litros.
- **Flujo de leche:** Velocidad a la que sale la leche durante el ordeño, normalmente medida como kg/min.
- **Ordeño completo:** Es en donde se extrae la leche desde las cuatro ubres.
- **Ordeño incompleto:** Es en donde ocurrió una inconveniencia a la hora de la extracción de una o de todas las ubres, esto ocurre por varias razones como patadas, falla de colocación, entre otras.
- **Patada:** Evento en donde la vaca patea debido por incomodidad o inconformidad durante el proceso de ordeña, ya sea por el robot o casos externos..
- **Incidencia:** Cualquier evento anómalo registrado en el VMS.
- **Pezionera:** Componente del robot el cual se coloca en cada ubre de la vaca.
- **Cuarto de la ubre:** Cada una de las secciones de la ubre, esto es debido a que el VMS registra por cada cuarto.
- **Hato lechero:** Conjunto de vacas con misión de ser ordenadas.

Terminología Técnica:

- **CRISP-DM:** Tipo de metodología para proyectos de minería de datos, el cual cuenta con seis etapas: entendimiento del negocio, entendimiento de los datos, preparación, modelado, evaluación y despliegue.
- **Minería de datos:** Es un proceso en donde se analizan grandes volúmenes de información con el propósito de descubrir patrones, tendencias y relaciones ocultas.
Ejemplo: Encontrar las variables que ayudan a explicar los ordeños largos.
- **Inteligencia Artificial:** Tecnología que permite a los sistemas pensar, aprender y tomar decisiones como si fueran humanos. **Ejemplo:** Modelo que anticipe los ordeños incompletos.

- **Aprendizaje Automático:** Rama de la inteligencia artificial que hace que los modelos tengan la oportunidad de aprender sin necesidad de que los datos sean programados de manera explícita. **Ejemplo:** Entrenar un modelo mediante datos históricos.
- **Variable:** Característica medida en cada registro, ya sea numérica o categórica. **Ejemplo:** Flujo de leche, franja horaria, patadas, etc..
- **Hipótesis:** Formar un enunciado el cual se plantea para ser comprobado con los datos. **Ejemplo:** Los ordeños incompletos tienden a durar más.
- **Prueba de hipótesis:** Es en donde se pone a prueba la hipótesis descrita para verificar si es cierta o no. **Ejemplo:** Comparar los tiempos de ordeños completos con los incompletos.
- **Valor P (P-value):** Probabilidad de observar resultados al menos tan extremos como obtenidos si la hipótesis nula fuera cierta. **Ejemplo:** Un valor de p menor a 0.005 indica que la hipótesis nula es falsa.
- **Prueba T:** Pruebas que comparan promedios de dos grupos. **Ejemplo:** Utilización entre franjas horarias.
- **Correlación:** Medida de fuerza y dirección de la relación lineal entre dos variables numéricas. **Ejemplo:** Relación entre la duración del ordeño y la leche producida.
- **Regression:** Modelo el cual estima como una o varias variables explican el valor de la otra. **Ejemplo:** Predecir la duración de ordeño a partir de la producción.
- **Clasificación:** Tarea del modelado el cual asigna registros a categorías. **Ejemplo:** Clasificar ordeños como completos o incompletos.
- **Extracción, Transformación y Carga (ETL):** Etapa previa a un proyecto donde se recupera información de las fuentes, se transforma en un formato adecuado para trabajar y analizar y se carga en el sistema para trabajar con ella.
- **Análisis Exploratorio de Datos (EDA):** Etapa inicial en donde se visualizan los datos para aprender su estructura. **Ejemplo:** Histogramas de duración, gráficos de utilización del robot por hora.
- **Limpieza de datos:** Etapa en donde se corrigen los datos o se eliminan datos erróneos, duplicados o faltantes. **Ejemplo:** Quitar ordeños con duración de 0 segundos.
- **Valor Atípico:** Valores que se alejan demasiado del resto de los otros datos. **Ejemplo:** Un ordeño de 100 minutos cuando el promedio tiende a ser de 7 minutos.

- **Valores faltantes:** Registros en donde no hay datos para una variable. **Ejemplo:** Ordeños sin registro del flujo.
- **Significancia estadística:** Indica que un registro es poco probable que se deba al azar. **Ejemplo:** Determinar si una franja horaria tiene menor tiempo.

2.5 Costos y Beneficios

Este proyecto se desarrolla con fines académicos y de investigación, por lo que no se espera obtener un beneficio económico directo durante su desarrollo. El objetivo principal es analizar los datos generados por el sistema VMS para encontrar patrones y relaciones que ayuden a comprender mejor la utilización del robot y el comportamiento de los ordeños.

Por esta razón, realizar un cálculo exacto del beneficio económico sería poco representativo, ya que todavía no se conoce si los patrones encontrados llevarán a cambios en la operación ni cuál sería el efecto real de estos. Sin embargo, si los resultados del proyecto fueran utilizados posteriormente en el ordeño, sí habría costos y beneficios asociados a su implementación.

Costos potenciales

En un escenario de implementación real, los principales costos estarían relacionados con el desarrollo y mantenimiento de la solución. Por ejemplo, sería necesario considerar el tiempo del personal encargado de analizar y monitorear los datos, así como los costos operativos de los recursos tecnológicos necesarios para almacenar y procesar la información relevante.

También podrían existir costos asociados con la implementación de las recomendaciones obtenidas a partir del análisis. Si se identificara la necesidad de modificar el proceso de ordeño, estos cambios tendrían que ser evaluados y supervisados por personal especializado.

Para este proyecto no se asignará un valor monetario, debido a que no se realizará una implementación operativa y no se cuenta con información suficiente sobre los costos internos.

Beneficios potenciales

El principal beneficio del proyecto sería generar conocimiento sobre los factores que afectan la utilización del VMS y la duración de los ordeños. Este conocimiento podría utilizarse posteriormente para tomar decisiones que permitan aprovechar mejor la capacidad del VMS y reducir tiempos improductivos. Esto es especialmente relevante debido a que el tiempo que una vaca pasa esperando para utilizar el robot es tiempo que no puede dedicar a otras actividades importantes, como alimentarse o descansar, y afecta directamente su producción.

En caso de que estas decisiones lograran mejorar la eficiencia del proceso de ordeño, también podría existir un beneficio económico. Un mejor aprovechamiento del robot podría permitir atender la demanda de ordeño de manera más eficiente y, dependiendo de los resultados, contribuir a mejorar la producción o evitar pérdidas asociadas con problemas en los ordeños.

Sin embargo, estos beneficios son considerados potenciales, ya que uno de los propósitos de la investigación es justamente determinar si estas relaciones existen y qué tan importantes son.

Comparación costo-beneficio

Para el alcance actual, el beneficio del proyecto se encuentra principalmente en la generación de conocimiento útil para el CAETEC, más que en un retorno económico inmediato.

Si el proyecto fuera llevado posteriormente a una implementación real, los costos principales corresponderían al desarrollo, mantenimiento, monitoreo y posibles cambios en la operación. A cambio, los resultados podrían contribuir a mejorar el aprovechamiento del VMS, reducir tiempos improductivos, identificar ordeños problemáticos y apoyar la toma de decisiones.

Por lo tanto, en esta etapa no es posible determinar que los beneficios económicos sean mayores que los costos, ya que primero es necesario comprobar las hipótesis planteadas y determinar si los patrones encontrados pueden convertirse en decisiones que generen una mejora real. En caso de continuar el proyecto hacia una implementación, se podría realizar un análisis económico más completo utilizando información como el valor de la leche producida, costos operativos, y cambios observados en producción y utilización del VMS.

3. Objetivos de Minería de Datos

En esta sección se presentan los objetivos de minería de datos, los cuales traducen las necesidades y preguntas planteadas en los objetivos de negocio a tareas que puedan ser abordadas mediante el análisis y modelado de los datos disponibles. Estos objetivos permiten orientar el análisis hacia la identificación de patrones, tendencias y condiciones relacionadas con la formación y comportamiento de las colas en el sistema de ordeño automático (VMS).

Para esta etapa se siguieron los entregables establecidos por la metodología CRISP-DM, por lo que no fue necesario realizar adaptaciones a los entregables correspondientes a esta sección.

3.1 Objetivo 1

Segmentar los periodos de operación del robot de ordeña mediante clustering, de acuerdo con su nivel de ocupación, con el propósito de distinguir periodos con y sin formación de colas.

Criterios de éxito:

- Obtener un coeficiente de silueta mayor a 0.5.
- Obtener un índice de Davies-Bouldin menor a 1.0.

3.2 Objetivo 2

Identificar mediante reglas de asociación las combinaciones de variables temporales y operativas, que se presentan de manera recurrente durante la formación de las colas.

Criterios de aceptación:

- Obtener reglas con un lift mayor a 1.5.
- Obtener reglas con una convicción mayor a 1.5.

3.3 Objetivo 3

Construir un modelo de clasificación, que permita predecir la formación de colas en periodos de tiempo específicos a partir de las variables temporales y operativas encontradas antes.

Criterios de aceptación:

- Obtener un PR-AUC de al menos el doble del porcentaje de periodos con cola.
- Obtener un F1-score al menos 0.10 mayor que el de una regla simple que prediga la presencia de una cola cuando ésta se haya presentado a la misma hora del día anterior.

4. Plan del Proyecto

En esta sección se presenta la planificación general del proyecto, definiendo las actividades necesarias para cumplir con los objetivos establecidos, así como su organización y seguimiento a lo largo del tiempo. Para ello, se utilizan herramientas que permiten dividir el trabajo en tareas específicas y evaluar el avance del proyecto conforme a lo planeado.

Para esta etapa se siguieron los entregables establecidos por la metodología CRISP-DM, por lo que no fue necesario realizar adaptaciones a los entregables correspondientes a esta sección.

4.1 Work Breakdown Structure (WBS)

El Work Breakdown Structure (WBS) presenta la división del proyecto en las etapas de CRISP-DM, actividades y tareas más específicas, facilitando la organización del trabajo y la asignación de responsabilidades entre los integrantes del equipo. Su estructura permite visualizar de manera clara las actividades necesarias para completar cada fase del proyecto.

El WBS del proyecto, incluyendo las etapas, actividades y tareas, puede consultarse [aquí](#).

4.2 Plan de Valor Ganado (PVG)

El Plan de Valor Ganado (PVG) se utiliza para dar seguimiento al progreso del proyecto, comparando el valor y costo planeados con el valor aportado y el costo invertido a lo largo de su desarrollo. Esto permite identificar posibles diferencias respecto a la planificación original y tener una visión general del cumplimiento de las actividades y tiempos establecidos.

El Plan de Valor Ganado del proyecto completo y actualizado al día puede consultarse [aquí](#).

4.3 Evaluación de Herramientas y Técnicas

En esta sección se realiza una evaluación inicial de las herramientas y técnicas que podrán utilizarse durante el desarrollo del proyecto, considerando su utilidad para los objetivos planteados. Esta evaluación contempla las herramientas disponibles para el procesamiento y análisis de los datos. Esta evaluación inicial busca determinar cuáles de las herramientas disponibles son adecuadas para las necesidades del proyecto antes de avanzar en el proyecto.

La evaluación inicial de las herramientas disponibles para el proyecto puede consultarse [aquí](#).