

Tecnológico de Monterrey

Tecnológico de Monterrey.

Inteligencia Artificial Avanzada para la Ciencia de Datos
"Reto CAETEC | Data Understanding"

Profesores:
Benjamín Valdés Aguirre
Eduardo Daniel Juárez Pineda

Jorge Armando Garzón Varela | A01707102
Santiago Alducin Villaseñor | A01707122
Sebastián Pérez García | A01707346
Roberto Serna Niño | A01709577
Kamila Jeannette Martinez Ibarra | A01711833

Fecha de entrega: 20 de octubre de 2026

Índice

1 Introducción

- 1.1 Objetivo de la fase de Data Understanding
- 1.2 Adaptaciones CRISP-DM
- 1.3 Objetivo del reporte
- 1.4 Contenido del reporte

2 Reporte de obtención y carga de datos

- 2.1 Datasets
- 2.2 Organización final de los datos
- 2.3 Conclusiones

3 Reporte de descripción de los datos

- 3.1 Formato de los datos
- 3.2 Cantidad de los datos
- 3.3 Características de los datos
- 3.4 Evaluación de los datos

4 Reporte de exploración de los datos

- 4.1 Primeros descubrimientos
- 4.2 Visualización de los datos
- 4.3 Patrones y subcolecciones
- 4.4 Hipótesis iniciales del proyecto

5 Reporte de calidad de los datos

- 5.1 Criterios de evaluación
- 5.2 Verificación de la calidad de los datos
- 5.3 Resumen de problemas y tratamiento
- 5.4 Limitaciones
- 5.5 Conclusiones

6 Conclusiones generales

1. Introducción

Para el análisis de colas de ordeño utilizamos datos del CAETEC sobre los tiempos de ordeña y la producción de las vacas en los robots de ordeño (VMS). Este documento corresponde a la segunda fase de la metodología CRISP-DM, el entendimiento de los datos (Data Understanding).

1.1 Objetivo de la fase de Data Understanding

El objetivo de esta fase es conocer a fondo los datos disponibles antes de prepararlos y modelarlos. Para ello se obtienen y cargan los datos en un ambiente de trabajo, se describen sus características generales, se exploran para encontrar los primeros patrones y relaciones, y se verifica su calidad. Con esto se determina si los datos permiten responder a los objetivos de minería de datos definidos en la fase de Business Understanding y qué problemas deben resolverse en la fase de preparación.

1.2 Adaptaciones CRISP-DM

Para el desarrollo del proyecto se sigue la metodología CRISP-DM como guía para estructurar las actividades correspondientes. En lo que respecta a la etapa de Business Understanding, se respetaron todas las actividades y entregables establecidos por la metodología, por lo que no fue necesario realizar adaptaciones a la estructura original.

1.3 Objetivo del reporte

Este reporte reúne en un solo documento los cuatro entregables de la fase de Data Understanding. Su propósito es documentar qué datos tenemos, cómo los obtuvimos, cómo son, qué encontramos al explorarlos y qué tan confiables son, de manera que las decisiones de la fase de Data Preparation queden justificadas y cualquier integrante del equipo pueda reproducir el proceso.

1.4 Contenido del reporte

- **Reporte de obtención y carga de datos (sección 2):** lista los conjuntos de datos adquiridos, su ubicación, el método con el que se obtuvieron y cargaron, los problemas encontrados durante la obtención y las soluciones aplicadas.
- **Reporte de descripción de los datos (sección 3):** describe el formato de los datos, la cantidad de registros y variables, el significado de los campos y sus características generales, y evalúa si los datos cubren los requerimientos del proyecto.
- **Reporte de exploración de los datos (sección 4):** presenta los primeros hallazgos obtenidos con estadísticas, consultas y visualizaciones, los patrones y subconjuntos de interés, y el estado de las

hipótesis del proyecto respecto a los objetivos de minería de datos.
- **Reporte de calidad de los datos (sección 5):** evalúa la completitud, unicidad, formato, validez, valores atípicos y cobertura de los datos, resume los problemas con su magnitud y define el tratamiento que se aplicará en la fase de preparación.

2. Reporte de obtención y carga de datos

Esta sección incluye para cada conjunto de datos: su ubicación, el método mediante el cual fue adquirido, los problemas encontrados durante su obtención y las soluciones implementadas para poder disponer los datos en las siguientes etapas.

2.1 Datasets

Dataset: Registros de ordeño en establo (Mar - Jun 25)

Descripción: Registros individuales de ordeño por vaca en formato CSV. Cada archivo corresponde a una vaca e incluye hora de inicio, acción, duración, producción en kg, número de ordeño, incidencias (patadas, ordeños incompletos, pezones no encontrados), mediciones por cuarto (DI, DD, TI, TD) y destino de la leche, entre otras variables aún por identificar. Contiene 7,249 registros. Aunque el nombre de la carpeta indica el periodo de marzo a junio de 2025, al leer las fechas algunos registros aparecen fuera de ese rango (por ejemplo, enero de 2025), probablemente porque el día y el mes se intercambiaron al interpretarlas.

Ubicación: Google Drive, carpeta compartida mediante acceso directo: Datos/DATOS vacas en establo marzo_junio_2025/ (archivos como 6232.csv, 2076.csv, 6003.csv, etc.).

Método de obtención / adquisición: Archivos proporcionados en formato CSV y almacenados en una carpeta de Google Drive compartida con el equipo. Desde Google Colab, se monta Drive y se localiza la carpeta con una función de búsqueda que no distingue mayúsculas de minúsculas. Después se leen todos los CSV cuyo nombre empieza con un número y se unen en un solo DataFrame, agregando la columna Origen_Archivo para conservar la trazabilidad.

Problemas encontrados:

- La carpeta contiene 37 archivos CSV, pero solo 34 corresponden a registros por vaca. Los demás son reportes generales con nombres distintos (por ejemplo reporte_180725.csv e inventario_total_180725.csv).
- La primera fila de cada archivo no contiene datos útiles, por lo que las cabeceras quedaban desplazadas al leerlos directamente.
- Algunas columnas se repetían y solo se diferenciaban por los títulos de la primera fila.
- Los archivos no incluyen el identificador de la vaca como columna; solo aparece en el nombre del archivo.
- Las fechas de los registros (por ejemplo, enero de 2025) no coinciden con el periodo indicado en el nombre de la carpeta (marzo–junio 2025).
- El acceso a la carpeta depende de que cada integrante cree un acceso directo en su propio Drive.

Soluciones implementadas: Se filtraron únicamente los archivos cuyo nombre inicia con un dígito, descartando los reportes generales. Se leyó cada CSV omitiendo la primera fila (skiprows=1) y se verificó que los 34 archivos tuvieran exactamente 36 columnas. Se agregó la columna Origen_Archivo para saber de qué archivo proviene cada registro. Se convirtió Hora de inicio a formato fecha-hora y se ordenó cronológicamente. Para corregir el desfase de fechas, se deben leer indicando que el día va primero (dayfirst=True) y comprobar que el rango quede entre marzo y junio de 2025. Se documentó en el notebook la instrucción de crear el acceso directo a la carpeta Datos para que todos puedan ejecutarlo.

Dataset: Producción de leche por sesión (histórico hasta enero 2026)

Descripción: Registros de cada sesión de ordeño realizada por los robots, uno por archivo de vaca. Incluye hora de inicio, duración, producción (kg), intervalo de ordeño, número de ordeño, robot utilizado (MS: VMS 1, VMS 2 y VMS 3), mediciones por cuarto, destino de la leche e incidencias como patadas, ordeños incompletos y pezones no encontrados. Consolidado contiene 278,968 registros y 44 columnas, de 201 vacas, entre el 13 de julio de 2022 y el 28 de enero de 2026. Es el dataset principal del proyecto porque contiene hora de inicio, duración y robot, variables necesarias para estudiar la formación de colas.

Ubicación: Google Drive: Datos/Datos vacas historico hasta enero 2026/TEC-UAQ-UNAM/ (archivos Excel .xlsx, uno por vaca; de los 404 archivos de la carpeta, 201 son de producción de leche por sesión).

Método de obtención / adquisición: Archivos Excel proporcionados en una carpeta de Google Drive compartida (aparentemente exportados del sistema de gestión del robot de ordeño; el usuario registrado en los datos es DelproCliente). Desde Colab se recorre la carpeta, se clasifican los archivos por prefijo en el nombre y se leen con pd.read_excel. El identificador de la vaca (ID_Vaca) se extrae del nombre del archivo y se agrega, junto con Origen_Archivo, a cada registro.

Problemas encontrados:

- Los archivos de la carpeta son de dos tipos (producción de leche y concentrado consumido) y están

mezclados, con estructuras diferentes.
- La primera fila de los archivos de producción es un encabezado extra que desplaza los nombres de columna.
- No hay una columna con el ID de la vaca; solo se encuentra en el nombre del archivo.
- Las duraciones e intervalos vienen en formatos mezclados (hh:mm:ss, mm:ss u objetos de hora), lo que impedía usarlos directamente como números.
- Calidad: cinco columnas tienen más de 90 % de valores nulos (RCS, Usuario, Razón de la desviación, Programa de lavado y Pezón); dos registros no tienen robot asignado (MS), y se detectaron dos traslapes entre ordeños consecutivos del mismo robot.
- Existe una diferencia de cobertura entre fuentes: 201 vacas en producción de leche contra 203 en concentrado consumido.

Soluciones implementadas: Se clasificaron los archivos por el prefijo de su nombre. Los de producción se leyeron omitiendo la primera fila (skiprows=1) y se les asignó una lista de nombres de columna, ya que varias columnas tenían el mismo nombre. El ID_Vaca se extrajo de los dígitos del nombre del archivo. Se creó la función a_min para convertir duraciones e intervalos de cualquier formato a minutos; no quedaron valores sin convertir. Se verificó que no existan registros duplicados (vaca + robot + hora de inicio) ni registros sin fecha válida. Las columnas casi vacías se identificaron como candidatas a descarte en la etapa de preparación, y los traslapes se excluyeron del cálculo de tiempo libre entre ordeños.

Dataset: Concentrado consumido

Descripción: Registros del consumo de concentrado por vaca a lo largo del tiempo. Incluye tipo de alimento (Feed1), fecha y hora del evento, cantidad consumida y consumo en materia seca. Contiene 130,315 registros de 203 vacas, del 28 de enero de 2025 al 28 de enero de 2026. Se utilizará como información complementaria sobre el comportamiento de las vacas.

Ubicación: Google Drive: Datos/Datos vacas histórico hasta enero 2026/TEC-UAQ-UNAM/ (archivos con nombre Concentrado consumido <ID>.xlsx; 203 archivos).

Método de obtención / adquisición: Archivos Excel proporcionados en la misma carpeta compartida que el dataset anterior. Se identifican por el prefijo Concentrado consumido en el nombre, se leen con pd.read_excel y se les agregan Origen_Archivo e ID_Vaca, este último extraído del nombre del archivo.

Problemas encontrados:

- Se encuentra mezclado con los archivos de producción de leche en una sola carpeta.
- No contiene el ID de la vaca como columna.
- Su estructura es distinta a la de producción de leche (no requiere omitir la primera fila).
- Cubre 203 vacas, mientras que producción de leche cubre 201, y solo abarca un año (enero 2025 a enero 2026), frente a los más de tres años del dataset principal.
- La columna Consumido Mat. Seca es idéntica a Consumido en la muestra revisada y Alimento solo tiene un valor, por lo que aportan poca información.

Soluciones implementadas: Se separaron los archivos por prefijo y se leyeron con la estructura adecuada, sin omitir filas. Se agregaron Origen_Archivo e ID_Vaca para poder relacionar este dataset con los demás. Se consolidó en el DataFrame concentradoConsumido y se documentó su alcance temporal para tenerlo en cuenta al combinarlo con los otros datos.

2.2 Organización final de los datos

Los tres datasets se leen desde una estructura común de carpetas en Google Drive y se cargan en Colab en DataFrames de pandas. Cada registro conserva la columna Origen_Archivo, y los datasets por vaca incluyen además ID_Vaca, lo que permite identificar el origen de cada dato en las etapas posteriores de exploración, limpieza y preparación.

```
Datos/
├── DATOS vacas en establo marzo_junio_2025/
│   ├── 6232.csv 2076.csv 6003.csv ... (34 archivos uno por vaca)
│   ├── reporte_180725.csv (no utilizado)
│   └── inventario_total_180725.csv (no utilizado)
└── Datos vacas historico hasta enero 2026/
    └── TEC-UAQ-UNAM/
        ├── Producciones de leche por sesión <ID>.xlsx (201 archivos)
        └── Concentrado consumido <ID>.xlsx (203 archivos)
```

DataFrames resultantes en el notebook:

- **df_consolidado:** 7,249 filas y 36 columnas. Viene de los CSV de marzo–junio 2025.
- **prodLecheSesion:** 278,968 filas y 44 columnas. Viene de los Excel de producción de leche por sesión.
- **concentradoConsumido:** 130,315 filas y 6 columnas. Viene de los Excel de concentrado consumido.

2.3 Conclusiones

La etapa de obtención de datos permitió reunir y organizar las diferentes fuentes necesarias para el desarrollo del proyecto. Durante este proceso se identificaron problemas relacionados principalmente con la organización de los archivos (tipos mezclados en una misma carpeta, un archivo por vaca y sin identificador interno), el formato de los datos (cabeceras desplazadas y duraciones en formatos mezclados) y la calidad de algunas columnas (alto porcentaje de nulos). Las soluciones implementadas permitieron consolidar los datos en tres DataFrames, con trazabilidad por archivo y por vaca, y establecer una base adecuada para continuar con las siguientes etapas del entendimiento de los datos.

---

3. Reporte de descripción de los datos

Este reporte describe las características superficiales de los datos obtenidos: su formato, la cantidad de registros y variables, el significado de los campos y otras características generales. También evalúa si los datos disponibles son suficientes para los requerimientos del proyecto.

Los datos proporcionados por el CAETEC incluyen información de producción, tiempos de ordeño, mediciones de cada cuarto de la ubre y posibles señales de problemas de salud de las vacas.

3.1 Formato de los datos

Se nos compartieron archivos en formato CSV y Excel (.xlsx) como fuente de datos. Estos se trabajan en Python como DataFrames de la librería pandas.

3.2 Cantidad de los datos

Contamos con 34 archivos de la carpeta «DATOS vacas en establo marzo_junio_2025» y 404 archivos de la carpeta «Datos vacas historico hasta enero 2026/TEC-UAQ-UNAM», de los cuales 203 son de consumo de concentrado y 201 de producción de leche. Estos se organizaron en tres DataFrames, cuyas variables se agrupan por categoría en las siguientes tablas. En los nombres de las variables, DI, DD, TI y TD se refieren a los cuartos delantero izquierdo, delantero derecho, trasero izquierdo y trasero derecho de la ubre.

df_consolidado: 7,249 filas $\times$ 36 columnas (archivos CSV de marzo a junio de 2025).

Categoría	Variables / columnas
Información base	hora_inicio, accion, duracion, produccion_kg, numero_ordeños, rcs_celulas_ml, patada, incompleto, pezones_no_encontrados
Estado AMD	estado_amd_ubre, estado_amd_pezon
Media de flujos	media_flujos_di, media_flujos_dd, media_flujos_ti, media_flujos_td
Sangre (ppm)	sangre_di, sangre_dd, sangre_ti, sangre_td
Conductividad	conductividad_di, conductividad_dd, conductividad_ti, conductividad_td
Flujo máximo	flujo_maximo_di, flujo_maximo_dd, flujo_maximo_ti, flujo_maximo_td
Producción	produccion_di, produccion_dd, produccion_ti, produccion_td
Otros	eo_po, usuario, destino_leche, razon_de_desviacion

Cuadro 1: Variables de df_consolidado.

prodLecheSesion: 278,968 filas $\times$ 44 columnas (archivos Excel de producción de leche por sesión).

Categoría	Variables / columnas
Información base	hora_inicio, numero_ordenio, duracion, produccion_kg, rcs_celulas_ml, intervalo_ordenio
Producción por cuarto	produccion_di, produccion_dd, produccion_ti, produccion_td
Estado MD	estado_md_ubre, estado_md_pezon
Media de flujo	media_flujo_di, media_flujo_dd, media_flujo_ti, media_flujo_td
Flujo máximo	flujo_maximo_di, flujo_maximo_dd, flujo_maximo_ti, flujo_maximo_td
Sangre (ppm)	sangre_di, sangre_dd, sangre_ti, sangre_td
Conductividad	conductividad_di, conductividad_dd, conductividad_ti, conductividad_td
Contadores de monitoreo	contador_ubre, contador_di, contador_dd, contador_td, contador_ti
Incidencias	patada, incompleto, pezones_no_encotnrados, mdi
Otros	destino_leche, razon_desviacion, programa_lavado, ms, usuario

Cuadro 2: Variables de prodLecheSesion.

concentradoConsumido: 130,315 filas $\times$ 6 columnas (archivos Excel de concentrado consumido).

Categoría	Variables / columnas
Consumo	alimento, hora_evento, consumo, consumido

Cuadro 3: Variables de concentradoConsumido.

3.3 Características de los datos

La información de ordeño proviene de 201 vacas distintas, ordeñadas entre el 13 de julio de 2022 y el 28 de enero de 2026 (1,295 días) en alguno de los tres robots de ordeño (VMS 1, VMS 2 y VMS 3).

Los datos registran la producción de leche de cada ordeño y diferentes mediciones de cada cuarto, como la cantidad de sangre, la conductividad de la leche y el flujo, además de incidencias como patadas u ordeños incompletos. Estas variables ayudan a entender el proceso de ordeño de cada vaca, la cantidad y calidad de la leche y posibles problemas de salud.

3.4 Evaluación de los datos

En un primer momento, la información disponible parece suficiente. Contamos con más de 278 mil registros de producción de leche de 201 vacas a lo largo de aproximadamente tres años y medio, con información detallada de cada cuarto, de producción, de posibles problemas de salud y de la calidad de la leche. En conjunto, estos datos parecen suficientes para estudiar cómo la temporalidad afecta a las colas de ordeño, por lo que podemos continuar con un entendimiento más detallado buscando patrones en el comportamiento de las vacas.

4. Reporte de exploración de los datos

Este reporte presenta los primeros hallazgos obtenidos al explorar los datos mediante estadísticas, consultas y visualizaciones. Incluye los valores faltantes y atípicos detectados, los descubrimientos de interés, los patrones y subconjuntos relevantes, y el estado de las hipótesis iniciales del proyecto.

El objetivo de esta etapa es determinar si se pueden cumplir los objetivos de minería de datos planteados en la fase anterior, que son:

- Encontrar una correlación media o fuerte y estadísticamente significativa ($p < 0.05$) entre diferentes variables, o su combinación, y la formación de colas, para su aplicación en el modelo.
- Determinar la significancia del ciclo de lactancia y su efecto en las colas.

4.1 Primeros descubrimientos

Valores faltantes o atípicos

La cantidad de valores nulos por variable tiene sentido dentro del contexto. Varias columnas tienen nulos cuando no hubo un registro, como en el caso de las patadas o de las desviaciones. En este punto solo destacan usuario y rcs_celulas_ml, que están vacías en todo el dataset. También hay variables con un porcentaje de nulos de entre 1 y 5 %; estos faltantes coinciden en varias variables a la vez, lo que indica registros con información incompleta. Por ejemplo, cinco variables relacionadas con el flujo de leche y su estado sanitario tienen 3.94 % de nulos.

En el análisis temporal del uso de los robots se verificó que no hubiera registros incongruentes, como un robot usado por varias vacas al mismo tiempo o una vaca registrada en dos robots a la vez. Solo se encontraron dos registros incongruentes.

Con base en los porcentajes de nulos y en las variables que no cambian de valor (varianza 0), identificamos las variables que no aportan información útil al modelo y de las que se puede prescindir:

Variable	% nulos	Motivo
rcs_celulas_ml	100.00	Completamente vacía
usuario	100.00	Completamente vacía
razon_desviacion	99.45	Casi vacía
programa_lavado	94.37	Sin variabilidad en los datos

Cuadro 4: Variables candidatas a descarte.

En un análisis estadístico de anomalías encontramos pocos valores atípicos: la duración del ordeño, el intervalo entre ordeños, la producción (kg), la conductividad promedio, el flujo promedio por cuarto y la sangre promedio tienen alrededor de 1 % de valores anormales.

No hay información de cuándo las vacas están en secado, pero se puede inferir a partir de los intervalos entre ordeños. Como una lactancia dura alrededor de 305 días y el secado aproximadamente 60 días, consideramos como secado los intervalos de entre 45 y 90 días. Con este criterio, 133 vacas tienen un secado registrado, 61 no han tenido secado porque tienen menos de un año de datos y 7 son casos atípicos con más de un año sin secado.

Descubrimientos de interés

- El robot VMS 1 es el más utilizado de los tres, con alrededor de 5,000 ordeños más que el VMS 2, que ocupa el segundo lugar.
- Los datos abarcan de julio de 2022 a enero de 2026.
- El tiempo libre entre ordeños aporta información importante: el mínimo es de 0.10 minutos y la mediana de 1.22 minutos; a partir del tercer cuartil sube hasta 12 minutos y el percentil 90 llega a 34 minutos. Un tiempo libre corto puede indicar una cola en la que las vacas pasan rápidamente, mientras que un tiempo libre largo puede deberse a mantenimiento del robot o a horas de poco uso.
- Comparamos los ordeños con y sin posible cola según la duración, el intervalo y las incidencias. Las diferencias entre ambos grupos son pequeñas (tabla 5).
- No hay ningún día en el dataset en el que algún robot no se haya utilizado.
- Hay huecos mayores a 60 minutos en los que los robots no se usaron; su media es de alrededor de 85 minutos, con máximos de 300 a 700 minutos (5 a 11.5 horas).
- A lo largo de los años aumentan las vacas activas y los ordeños por vaca, lo que explica el aumento de la leche producida.
- Existen 7 vacas con más de un año de historial que no muestran ningún secado, posiblemente por lactancias extendidas.
- La mayoría de las vacas están en su primera lactancia (68). Con la cantidad de secados registrados se podría inferir el número de partos de cada vaca.
- La alimentación se da media hora después de que empiezan los periodos de mayor ordeño (7:30 y 14:30).
- La mayoría de las vacas tiene uno o dos ordeños al día; a partir del segundo, el porcentaje de cola aumenta un poco, y hay casos extremos de hasta 6 ordeños en un día.

Variable (promedio)	Sin posible cola	Con posible cola
Duración (min)	8.073	8.122
Intervalo (min)	574.276	574.213
Hubo patadas	0.167	0.155
Ordeño incompleto	0.143	0.100

Cuadro 5: Comparación de ordeños con y sin posible cola.

4.2 Visualización de los datos

Al graficar los ordeños se observa que los robots se usan más entre las 7 y las 10 horas y entre las 15 y las 18 horas, y que la cantidad de ordeños al día no varía durante la semana (figura 1). La distribución de la ocupación de los robots muestra la misma tendencia: las 4, 13 y 20 horas son las de menor ocupación, y solo en momentos poco comunes la ocupación supera el 80–90 %. Tampoco hay una diferencia clara entre los días de la semana; la ocupación normal de los robots está entre 30 y 70 %.

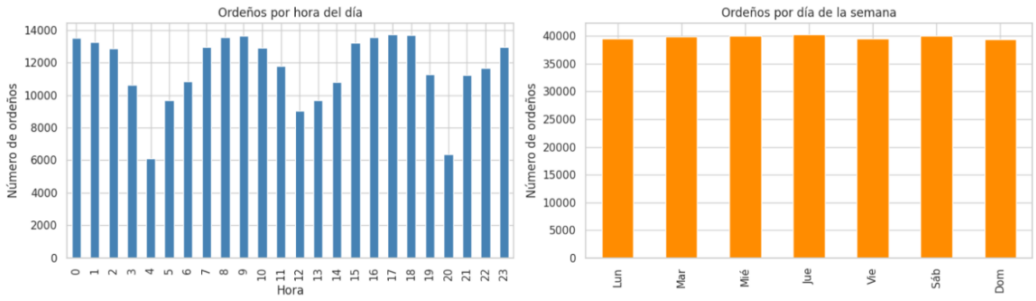


Figura 1: Ordeños por hora del día y por día de la semana.

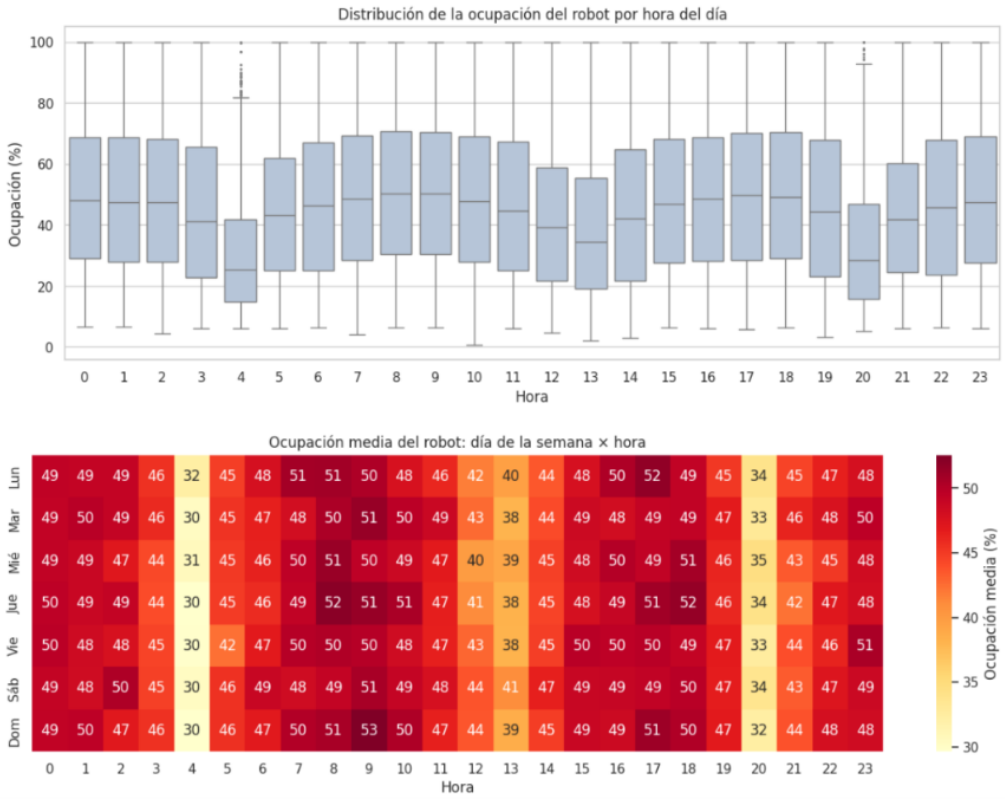


Figura 2: Distribución de la ocupación de los robots por hora y día de la semana.

La duración de los ordeños suele ser de alrededor de 7 minutos, el intervalo entre ordeños de unas 8 horas y la producción de entre 13 y 15 kg. Estas variables tienen una distribución cercana a la normal, con mayor

concentración del lado izquierdo y una cola derecha más larga. Los picos al final de cada histograma no representan una concentración real de casos: corresponden a la última barra, que agrupa todos los valores por encima del límite de la gráfica (16 minutos, alrededor de 21 horas y 30 kg).



Figura 3: Distribuciones de la duración, el intervalo y la producción por ordeño.

El tiempo libre entre ordeños tiene una distribución particular: la gran mayoría de los valores está muy cerca de 0, hay un pequeño aumento alrededor de 5–10 minutos y una cola larga hacia la derecha. El porcentaje de posible cola sigue de cerca la distribución de ocupación de los robots.

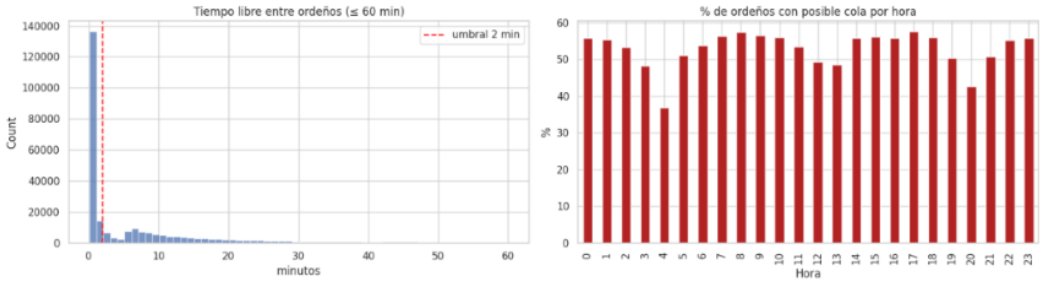


Figura 4: Distribución del tiempo libre entre ordeños y porcentaje de posible cola.

En la matriz de correlación se observa una relación fuerte entre el número de ordeño y la hora, lo que confirma los patrones de ordeño de las vacas. Hay una relación media entre el intervalo de ordeño y la producción (0.49), lo cual tiene sentido porque mientras más tiempo pasa entre ordeños, más leche se acumula en la ubre y mayor es la producción del siguiente ordeño. También hay una relación inversa entre el intervalo y el número de ordeño (-0.36), ya que con intervalos más largos la vaca se ordeña menos veces al día. La relación inversa entre el tiempo libre del robot y la posible cola (-0.48) es esperada por construcción, porque la posible cola se define a partir del tiempo libre (2 minutos o menos); por eso no se considera un hallazgo.

También hay relaciones débiles entre la duración y el intervalo de ordeño, entre la duración y la producción (a mayor tiempo de ordeño, mayor producción) y entre el intervalo de ordeño y el índice de mastitis, que a su vez tiene una relación muy débil con la producción y la duración. Por último, hay relaciones débiles negativas entre la duración y la producción con la cantidad de ordeños. El día de la semana no tiene relación con ninguna otra variable, y cualquier correlación menor a 0.1 se considera insignificante.

Respecto al primer objetivo de minería de datos, ninguna variable muestra una correlación lineal media

o fuerte con la posible cola: sin contar el tiempo libre, todos los coeficientes son menores a 0.1 en valor absoluto. Esto no significa que no exista relación. Por ejemplo, la correlación entre la hora y la posible cola es de 0.00, pero el porcentaje de posible cola varía aproximadamente entre 37 y 57 % según la hora del día, lo que indica una relación no lineal. Además, la cantidad de vacas activas y la ocupación de los robots sí se relacionan con la posible cola. Por ello, en las siguientes fases conviene usar variables derivadas, como una codificación cíclica de la hora o la ocupación del robot, y métodos capaces de capturar relaciones no lineales.

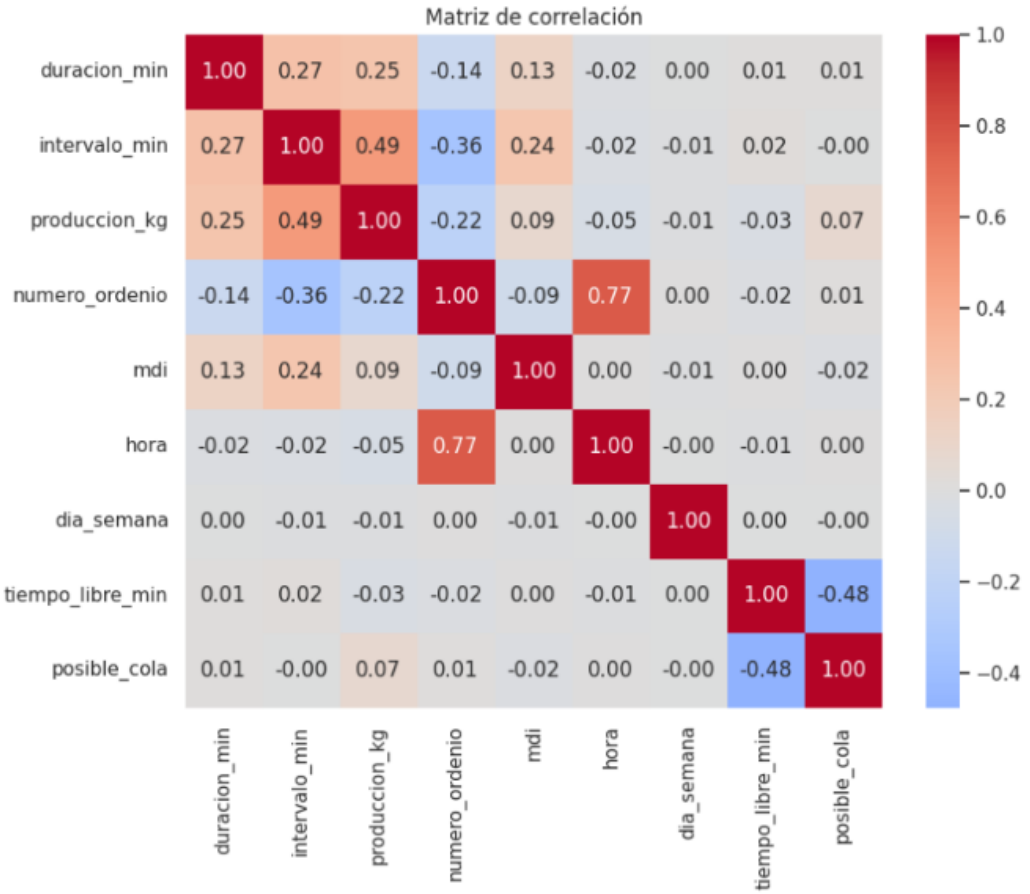


Figura 5: Matriz de correlación entre variables.

La siguiente gráfica muestra la cantidad de ordeños por día de cada robot a lo largo del periodo. Se observa un crecimiento constante en los ordeños diarios y algunos patrones a considerar, como caídas en los ordeños del tercer robot seguidas de un pico en el primero, o el aumento de ordeños del segundo robot en 2024. En el último año también aparecen caídas en días específicos que no se veían en los primeros años.

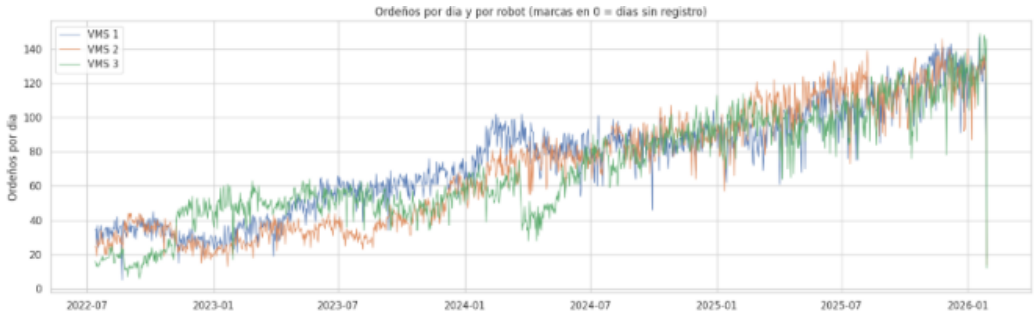


Figura 6: Ordeños por día y por robot a lo largo del tiempo.

Las horas con huecos de desocupación mayores a 60 minutos coinciden con las horas de poco uso de los robots, siendo las 4 y las 19 horas las que históricamente concentran más huecos. La duración de los huecos tiene una forma logarítmica: la mayoría de los huecos mayores a 60 minutos duran menos de dos horas, con una cola que se extiende hasta 5 horas. El pequeño pico al final de la gráfica no indica un aumento real de casos, sino que corresponde a la última barra del histograma, que agrupa todos los huecos de 5 horas o más (el máximo es de 709 minutos). Estos huecos largos son poco frecuentes y podrían relacionarse con eventos como averías o mantenimientos del robot.

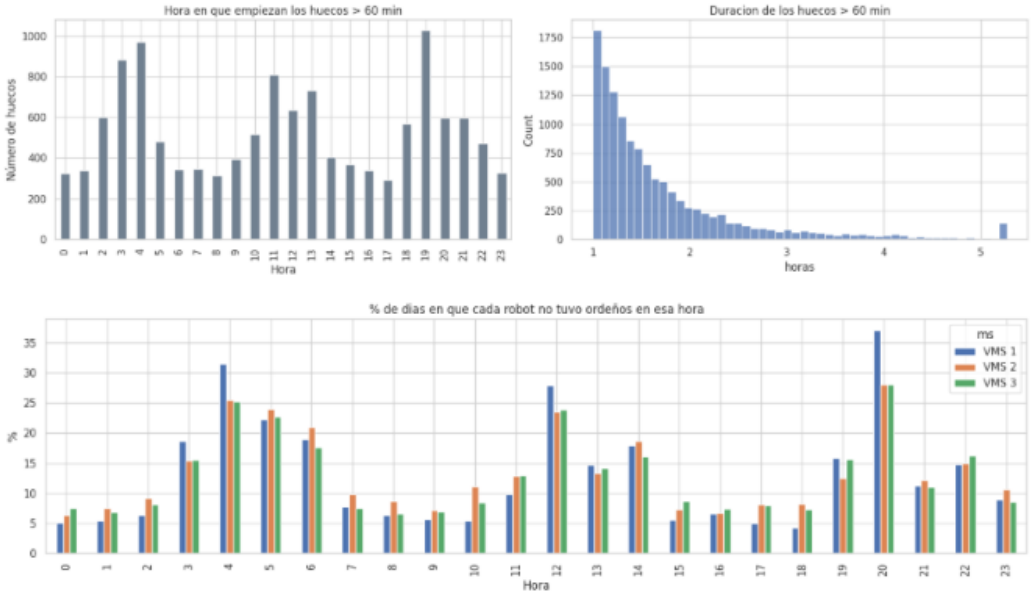


Figura 7: Horas y duración de los huecos de desocupación mayores a 60 minutos.

Con el tiempo, la cantidad de vacas activas y de ordeños ha crecido con una tendencia similar a la de la producción de leche, lo que explica ese comportamiento. Al crecer el número de vacas registradas también aumenta la cantidad de secados.



Figura 8: Vacas activas y registros por mes.



Figura 9: Vacas activas, vacas con huecos cortos y vacas con secado por año.

La producción, la duración de los ordeños y el tiempo libre son consistentes entre los tres robots, lo que muestra un uso similar de todos ellos.

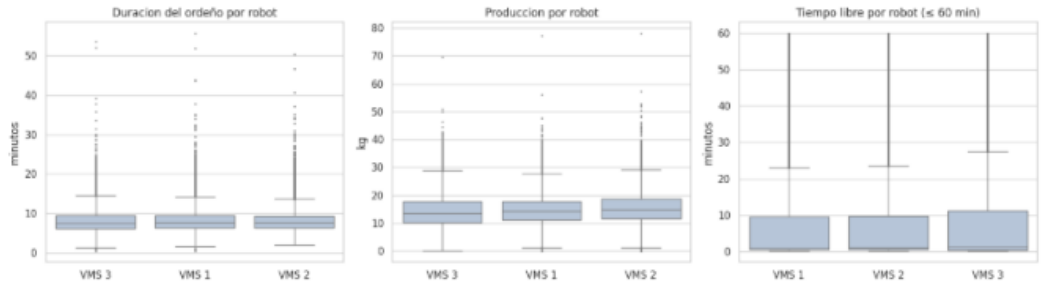


Figura 10: Comparación de producción, duración y tiempo libre entre robots.

Al acercarnos al tiempo libre menor a 5 minutos se observa un pico muy marcado cerca de 0.4 minutos. Este valor probablemente es el tiempo mínimo que tarda el robot entre una vaca y otra (salida, limpieza y entrada), lo que ayuda a justificar el umbral de 2 minutos usado para marcar una posible cola.

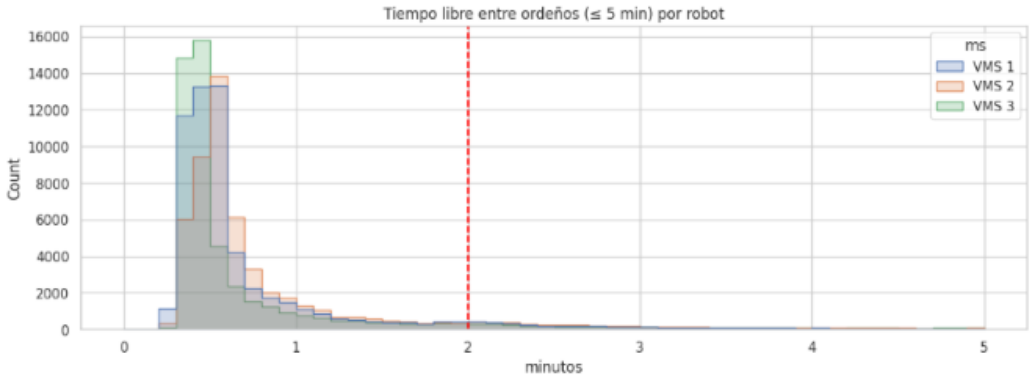


Figura 11: Distribución del tiempo libre menor a 5 minutos.

Existe una relación entre la duración del ordeño y la producción: normalmente un ordeño más largo indica mayor producción, aunque no en todos los casos. Además, la ocupación media de los robots crece de forma lineal con la cantidad de vacas, con una ocupación considerable a partir de 140 vacas.

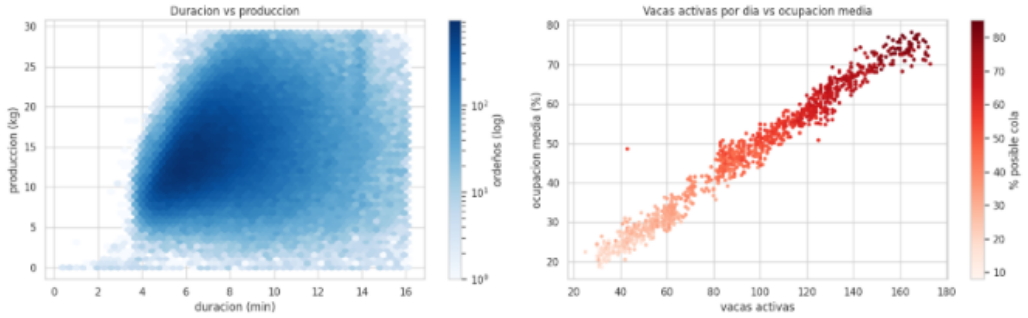


Figura 12: Relación entre duración y producción, y entre número de vacas y ocupación de los robots.

4.3 Patrones y subcolecciones

Debido al crecimiento del establo entre el inicio y el final del periodo, hicimos los cálculos por separado para 2024 y 2025 para comparar la producción, junto con una versión que elimina la tendencia (restando la media móvil de 30 días). Entre 2024 y 2025 crecieron los ordeños, la producción y, por lo tanto, las colas: la cantidad de vacas aumentó cerca de 45 % y la cola aumentó 24 %.

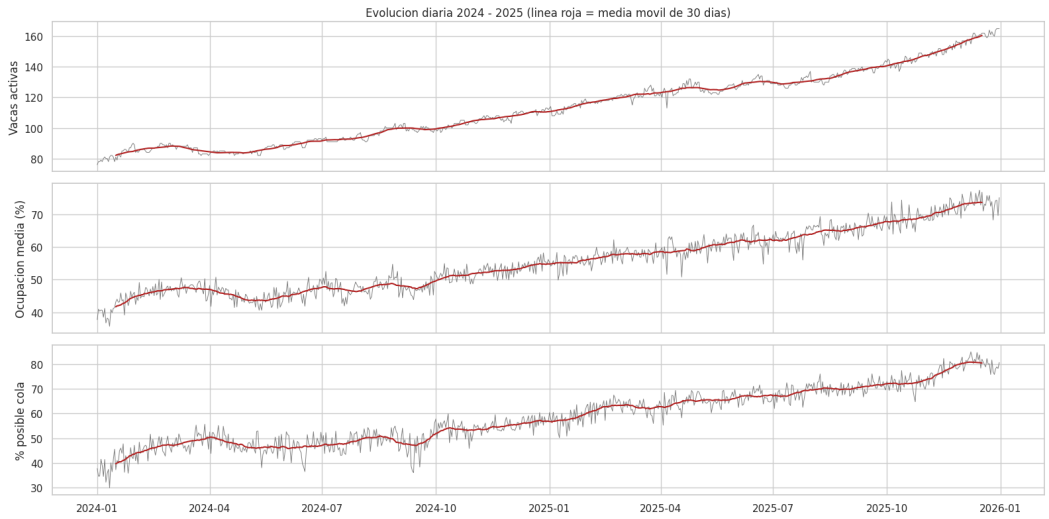


Figura 13: Evolución diaria de vacas activas, ocupación media y porcentaje de posible cola en 2024 y 2025 (la línea roja es la media móvil de 30 días).

En las vacas de primer parto, los primeros 30 días muestran un porcentaje menor de entradas en cola, que aumenta después del primer mes. En los últimos dos años, los meses 2 y 3 tienen un mayor porcentaje de cola que los periodos posteriores, que se mantienen bastante constantes. Además, los ordeños de los primeros 30 días son casi una tercera parte de los ordeños promedio de los siguientes ciclos.

Periodo	2022	2023	2024	2025	2026
0–30 días	1,017	1,623	2,746	2,742	241
30–90 días	1,670	3,805	7,049	6,472	622
90–180 días	521	6,637	9,363	10,977	654
180–365 días	0	8,476	12,939	17,307	1,164
$>$ 1 año	0	2,563	25,292	54,481	5,440

Cuadro 6: Número de ordeños por periodo y año.

Periodo	2022	2023	2024	2025	2026
0–30 días	15.2	27.3	48.8	63.8	73.0
30–90 días	24.6	34.7	52.0	71.0	84.9
90–180 días	27.3	34.3	54.0	70.5	81.0
180–365 días	–	32.5	49.6	69.4	79.6
$>$ 1 año	–	31.9	50.1	69.4	80.8

Cuadro 7: Porcentaje de entradas en cola por periodo y año.

Cuando las vacas no van a ordeñarse por sí solas en cierto tiempo, el personal del CAETEC las lleva manualmente (arreo). Como referencia inicial tomamos que, si el intervalo entre dos ordeños de la misma vaca es mayor a 4:30 horas, probablemente fue arreada. Sin embargo, al revisar la distribución, a partir de

las 10 horas consideramos que las vacas fueron arreadas porque no iban por sí mismas; este umbral ya se encuentra en la cola larga de la distribución, por encima de la media. Se trata de un supuesto, ya que el dataset no contiene esta información.

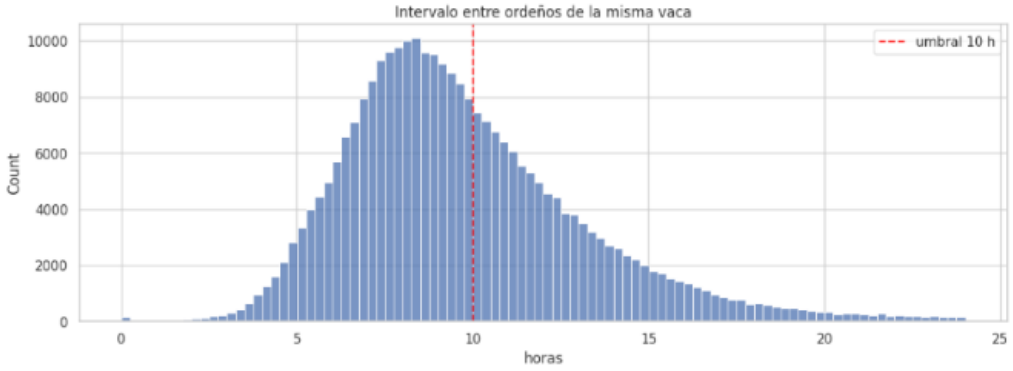


Figura 14: Distribución del intervalo entre ordeños y umbral de arreo.

A partir de las tendencias de lactancia, los periodos de secado y el tiempo en lactancia, determinamos la distribución de los ordeños según el grupo de la vaca y la etapa del ciclo de lactancia:

Etapa de lactancia	Multípara	Primer parto (probable)	Total
Fresca (0–100)	64,604	31,232	95,836
Alta producción (100–200)	48,874	30,758	79,632
Baja producción (200–305)	36,129	26,145	62,274
Extendida (> 305)	16,299	9,162	25,461
Total	**165,906**	**97,297**	**263,203**

Cuadro 8: Ordeños por grupo de vaca y etapa de lactancia.

También analizamos cómo la etapa de lactancia y el número de partos (multípara o primípara) afectan la producción, la duración de los ordeños y el intervalo entre ellos. Las vacas de primer parto tienen menos ordeños en general y producen menos leche por etapa que las multíparas; además, tardan más en el ordeño y tienen intervalos más largos. El porcentaje de veces que fueron llevadas al ordeño también es mayor, seguramente por el tiempo que les toma adaptarse al robot. Su porcentaje de entrada en cola es ligeramente menor, pero la cantidad de veces que les toca cola es considerablemente mayor.

Grupo	Etapa de lactancia	Vacas	Ordeños	Producción (kg)
Multípara	Fresca (0–100)	133	64,604	16.80
	Alta prod. (100–200)	120	48,874	16.45
	Baja prod. (200–305)	106	36,129	14.67
	Extendida (> 305)	75	16,299	12.23
Primer parto (probable)	Fresca (0–100)	164	31,232	12.93
	Alta prod. (100–200)	141	30,758	13.71
	Baja prod. (200–305)	126	26,145	13.37
	Extendida (> 305)	66	9,162	12.47

Cuadro 9: Métricas de producción por grupo y etapa de lactancia.

Grupo	Etapa	Duración (min)	Intervalo mediano (h)	% forzados	% en cola	Cola vs. mes (pp)
Multípara	Fresca	8.37	8.17	26.55	55.54	−1.10
	Alta prod.	7.98	8.74	33.58	58.12	0.89
	Baja prod.	7.56	9.49	43.45	56.20	−1.03
	Extendida	7.03	9.74	46.65	53.40	−5.08
Primer parto (probable)	Fresca	9.17	10.18	51.90	51.83	1.67
	Alta prod.	8.54	9.74	46.68	56.01	3.40
	Baja prod.	7.94	9.69	46.14	55.78	1.30
	Extendida	7.56	9.64	45.14	55.21	−1.23

Cuadro 10: Métricas de tiempos, arreo y comportamiento en cola por grupo y etapa de lactancia.

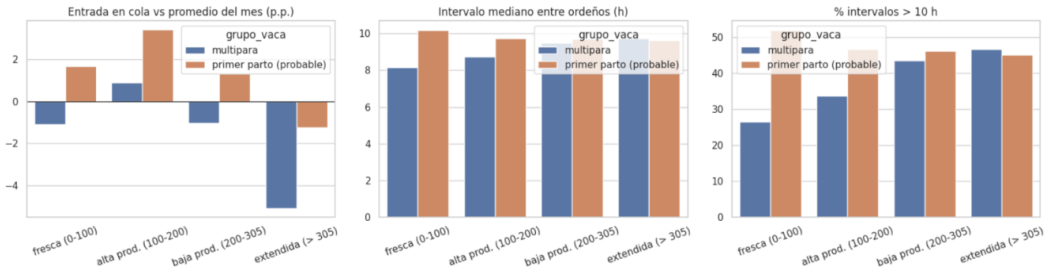


Figura 15: Entrada en cola respecto al promedio del mes, intervalo mediano entre ordeños y porcentaje de intervalos mayores a 10 h por etapa de lactancia.

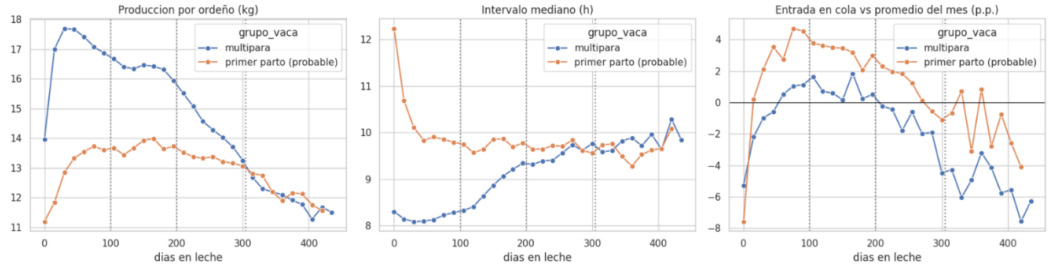


Figura 16: Producción por ordeño, intervalo mediano y entrada en cola respecto al promedio del mes según los días en leche.

4.4 Hipótesis iniciales del proyecto

Para cerrar, revisamos el estado de las hipótesis planteadas para el proyecto.

Hipótesis comprobadas

1. **Horario:** la ocurrencia de colas varía según la hora del día.
2. **Carga del sistema:** a mayor ocupación de los robots, mayor ocurrencia de colas.

Hipótesis que pueden volver a abordarse

1. **Alimentación:** las colas aumentan después de la entrega de alimento (7:30 y 14:30). Se observa un ligero aumento de la cola después de la alimentación, pero a las 7:30 es mínimo (2.9 %).
2. **Ciclo de lactancia:** la etapa de lactancia y el número de parto se asocian con la ocurrencia de colas. Respecto al promedio del mes, las vacas de primer parto entran en cola entre 2 y 4 pp más durante gran parte de la lactancia, aunque su porcentaje absoluto de entrada en cola es ligeramente menor que el de las multíparas.
3. **Producción y duración de ordeño:** se espera que los ordeños con mayor producción duren más.

Hipótesis rechazadas

1. **Día de la semana:** los fines de semana presentan un patrón de colas distinto.

Hipótesis pendientes

1. **Persistencia de la cola:** se espera que la cola tienda a mantenerse.
2. **Acumulación después de paros.**
3. **Poder predictivo temporal.**
4. **Combinación de variables.**

5. Reporte de calidad de los datos

Este reporte evalúa la calidad de los datos proporcionados por el CAETEC antes de pasar a la fase de preparación. El objetivo es identificar qué problemas tienen los registros, qué tan grandes son y cómo afectan el estudio de las colas de ordeño, para decidir qué datos se pueden usar tal como vienen, cuáles deben corregirse o marcarse y cuáles deben excluirse.

El análisis se centra en el dataset de producción de leche por sesión (histórico hasta enero de 2026), ya que es la fuente principal del proyecto. Este contiene 278,767 registros y 44 columnas de 201 vacas y 3 robots (VMS 1, VMS 2 y VMS 3), entre el 13 de julio de 2022 y el 28 de enero de 2026. Los datasets de concentrado consumido y de registros de ordeño de marzo a junio de 2025 se revisan de forma complementaria. Todas las cifras de este reporte provienen del notebook de Data Understanding.

5.1 Criterios de evaluación

Para ordenar la revisión agrupamos las verificaciones en seis dimensiones de calidad:

- **Completitud:** proporción de valores faltantes por variable y si esos faltantes representan pérdida de información o tienen un significado dentro del ordeño.
- **Unicidad:** existencia de registros duplicados o de ordeños que se traslapan en el tiempo.
- **Consistencia de formato:** que las fechas, duraciones e intervalos se interpreten correctamente y de la misma forma en todo el dataset.
- **Validez:** que los valores tengan sentido físico y biológico, como la duración, la producción, el flujo y el balance entre cuartos.
- **Valores atípicos:** valores que se alejan de la distribución general, evaluados con los criterios de tres desviaciones estándar y de rango intercuartílico (IQR).
- **Cobertura:** que el periodo, las vacas y los robots estén representados de manera continua y comparable a lo largo del tiempo.

5.2 Verificación de la calidad de los datos

Completitud y valores faltantes

Varias columnas del dataset tienen valores faltantes, pero no todos los nulos significan lo mismo. En la siguiente tabla se muestran las variables con nulos y la interpretación que les damos dentro del contexto del ordeño.

Variable	% nulos	Interpretación
rcs_celulas_ml	100.00	Sin información en ningún registro
usuario	100.00	Solo 2 registros con valor (DelproCliente)
razon_desviacion	99.45	Solo se llena cuando la leche se desvía y hay una razón registrada
programa_lavado	94.37	Solo se llena cuando hubo un lavado; tiene un único valor
estado_md_pezon	90.62	Solo se llena cuando hay pezones marcados
pezones_no_encotnrados	88.19	El nulo indica que el evento no ocurrió
incompleto	88.02	El nulo indica que el evento no ocurrió
patada	83.91	El nulo indica que el evento no ocurrió
mdi	7.80	Faltante real del índice de mastitis
Mediciones del cuarto TD	3.94	Faltante en las cinco mediciones del cuarto
Mediciones del cuarto DD	2.61	Faltante en las cinco mediciones del cuarto
Mediciones del cuarto DI	1.87	Faltante en las cinco mediciones del cuarto
Mediciones del cuarto TI	1.51	Faltante en las cinco mediciones del cuarto
ms	< 0.01	2 registros sin robot asignado

Cuadro 11: Variables con valores faltantes y su interpretación.

Las columnas rcs_celulas_ml y usuario no aportan información. La primera está vacía en todos los registros y la segunda solo tiene 2 valores, ambos DelproCliente. Estos 2 registros probablemente son los mismos que no tienen robot asignado, por lo que conviene revisarlos manualmente antes de descartarlos.

En las columnas patada, incompleto y pezones_no_encotnrados el nulo significa que el evento no ocurrió, por lo que no deben tratarse como datos faltantes ni eliminarse por su porcentaje de nulos. Lo mismo pasa con programa_lavado y razon_desviacion, que solo se llenan cuando hubo un lavado o una desviación. En el caso de las desviaciones encontramos además una inconsistencia: 15,730 ordeños tienen un destino distinto a Tanque (10,365 a Drenaje, 5,358 a Divert 3, 6 a Divert 2 y 1 a Divert 1), pero solo 1,542 tienen una razón registrada (1,498 por sangre por encima del umbral y 44 separadas manualmente). Es decir, cerca del 90 % de las desviaciones no tiene explicación en los datos.

Los faltantes reales se concentran en las mediciones por cuarto y en mdi. En los cuartos, los nulos aparecen al mismo tiempo en las cinco mediciones (producción, flujo medio, flujo máximo, sangre y conductividad), lo que apunta a un cuarto sin registro por una falla del sensor o a un cuarto no ordeñado, más que a registros dañados. También identificamos ceros que podrían ser faltantes registrados como 0, por ejemplo conductividades de 0.0, que no son posibles en leche.

Unicidad: duplicados y traslapes

No encontramos registros duplicados. No hay filas idénticas, ni registros con la misma vaca, robot y hora de inicio, ni registros de una misma vaca con la misma hora de inicio en robots distintos. Tampoco hay casos de una vaca ordeñándose en dos lugares al mismo tiempo.

Sí encontramos 2 traslapes en un mismo robot, es decir, ordeños que empiezan antes de que termine el

anterior. Son pocos y no afectan los resultados generales, pero se deben excluir del cálculo del tiempo libre entre ordeños, ya que generan tiempos negativos. Esta misma revisión también funciona como control de que un ordeño no esté repetido en dos archivos distintos, porque un ordeño duplicado aparecería como un traslape en su robot.

Consistencia de formato

Las duraciones e intervalos venían en formatos mezclados (hh:mm:ss, mm:ss y objetos de hora). Con la función a_min todos se convirtieron a minutos sin valores perdidos, y todas las fechas de inicio se pudieron interpretar. No hay duraciones menores o iguales a cero ni intervalos negativos.

Sin embargo, la columna intervalo_ordenio tiene un máximo de 1,439.95 minutos, prácticamente 24 horas. Al calcular el intervalo real con las fechas de ordeños consecutivos de cada vaca encontramos 2,845 intervalos mayores a 24 horas, mientras que la columna original no tiene ninguno. Esto indica que el formato hh:mm no conserva los días completos y que los intervalos largos aparecen recortados. Además, hay 403 intervalos iguales a 0 minutos. Por esta razón, el intervalo entre ordeños se calcula directamente con las fechas y la columna original solo se usa como referencia.

En el dataset de marzo a junio de 2025 el registro más antiguo aparece con fecha del 3 de enero de 2025, fuera del periodo que indica el nombre de la carpeta. Lo más probable es que el día y el mes se hayan intercambiado al leer las fechas, de modo que el 01/03/2025 se interpretó como 3 de enero en lugar de 1 de marzo. Antes de usar este dataset se deben leer las fechas indicando que el día va primero y comprobar que el rango quede entre marzo y junio.

Por último, los dos datasets de ordeño usan nombres distintos para las mismas variables, por ejemplo media_flujos_di y media_flujo_di o numero_ordeños y numero_ordenio, por lo que deben homologarse antes de combinarlos.

Validez de los valores

Como los datos provienen directamente de los sensores del VMS, hicimos una revisión breve de la lógica física y biológica de los ordeños:

- 165 ordeños (0.06 %) registran una producción de 0 kg.
- 8 ordeños duran menos de 1 minuto, 3 de ellos menos de 30 segundos, y 31 duran más de 30 minutos, con un máximo de 55.8 minutos.
- 1 ordeño tiene un flujo promedio mayor a 7 kg/min, lo cual no es realista.
- En 9 ordeños la suma de la producción de los cuatro cuartos difiere en más de 0.1 kg de la producción total registrada.
- La producción máxima es de 78.17 kg en un solo ordeño, mientras que el 95 % de los ordeños está por debajo de 24.34 kg.

En conjunto, estos casos representan una fracción muy pequeña del total y no cambian las conclusiones

generales. Aun así, un ordeño de 0 kg o de pocos segundos probablemente corresponde a un ordeño fallido o interrumpido, por lo que no debe usarse para analizar la producción ni la duración. En cambio, los ordeños largos sí ocuparon el robot, así que conviene conservarlos al calcular la ocupación aunque se excluyan de las estadísticas de duración.

Valores atípicos

Evaluamos los valores atípicos con dos criterios: tres desviaciones estándar alrededor de la media y el rango intercuartílico (IQR). Como se ve en la siguiente tabla, los resultados cambian según el criterio, sobre todo en las variables con distribuciones sesgadas.

Variable	Fuera de media ± 3 DE	Fuera de IQR
duracion_min	3,192 (1.15 %)	7,671 (2.75 %)
produccion_kg	1,562 (0.56 %)	3,821 (1.37 %)
conductividad_promedio	2,308 (0.83 %)	No evaluado
flujo_promedio_cuartos	1,889 (0.68 %)	No evaluado
sangre_promedio	2,389 (0.86 %)	No evaluado
mdi	No evaluado	35,211 (13.70 %)

Cuadro 12: Valores atípicos según cada criterio.

El criterio de tres desviaciones estándar supone una distribución cercana a la normal, lo que no se cumple en varias variables. En la sangre promedio la desviación estándar (144.0 ppm) es mucho mayor que la media (17.5 ppm). En el intervalo calculado con fechas la desviación estándar llega a 4,028 minutos porque incluye los periodos de secado, lo que deja el límite inferior en 0 y hace que el criterio pierda utilidad. Para estas variables es más adecuado usar el IQR, trabajar con el logaritmo de la variable o, en el caso del intervalo, excluir primero los huecos mayores a 24 horas.

En mdi, el 13.70 % de los registros queda por encima del límite del IQR. Por la forma de su distribución, estos valores no parecen errores sino parte natural del índice, por lo que no se eliminan. En su lugar, se puede crear una bandera que indique un mdi alto.

Cobertura temporal y de la población

Ningún robot tiene días completos sin registros en todo el periodo. Solo 4 días en total (2 en VMS 1, 1 en VMS 2 y 1 en VMS 3) muestran una actividad menor al 25 % de la mediana de los 30 días anteriores, lo que podría indicar días incompletos.

Al revisar por hora, cada robot pasa alrededor del 13 % de las horas del periodo sin ningún ordeño, y en 948 horas (3.05 % del periodo) los tres robots estuvieron sin actividad al mismo tiempo. Cuando los tres robots se detienen a la vez es más probable que se trate de un corte de luz, un mantenimiento o una pérdida de datos que de un comportamiento de las vacas, por lo que esas horas se excluyen del análisis de colas. También encontramos 12,689 huecos mayores a 60 minutos entre ordeños de un mismo robot, con un máximo de

709 minutos. Como no contamos con registros de lavados, fallas o mantenimientos, no es posible saber con certeza qué los provocó.

El problema de cobertura más importante es que el historial solo incluye a las vacas que actualmente están en el establo. Por eso los registros por mes pasan de 1,406 en julio de 2022 a 11,555 en diciembre de 2025 y las vacas activas pasan de 34 a 182, mientras que los ordeños por vaca se mantienen estables. Esto no solo afecta los conteos: las vacas que salieron del hato también usaban los robots, pero sus ordeños no aparecen en los datos. En los primeros años, el tiempo libre entre ordeños de un mismo robot se ve más largo de lo que realmente fue y la proporción de posibles colas queda subestimada. Por esta razón, la tendencia creciente de las colas entre 2022 y 2026 debe interpretarse con cuidado, ya que puede deberse en parte a la forma en que se exportaron los datos.

Por vaca también hay periodos sin registros. Encontramos 2,429 huecos de 1 a 2 días, 119 de 2 a 7 días, 41 de 7 a 30 días, 8 de 30 a 45 días, 160 de 45 a 90 días y 88 de más de 90 días. Los huecos largos corresponden principalmente al periodo de secado, mientras que los cortos pueden ser vacas en el corral de atención o registros faltantes.

Como no existen columnas de parto ni de secado, el ciclo de lactancia se infiere a partir de estos huecos, considerando como secado cualquier periodo de 40 días o más sin ordeño. Con este criterio, 133 vacas tienen al menos un secado, 61 no lo tienen porque cuentan con menos de un año de historial y 7 tienen un año o más de historial sin ningún secado, por lo que deben revisarse. Los secados duran en promedio 86.9 días, con un máximo de 272.9 días que probablemente corresponde a una vaca que salió del hato y regresó. Con esta reconstrucción se conocen los días en leche del 94 % de los ordeños.

Consistencia entre fuentes

- El dataset de concentrado consumido cubre 203 vacas, mientras que el de producción cubre 201, por lo que hay vacas sin correspondencia entre ambas fuentes.
- El concentrado solo abarca del 28 de enero de 2025 al 28 de enero de 2026, frente a los más de tres años del dataset de producción, por lo que cualquier análisis conjunto debe limitarse al periodo en común.
- En el concentrado, la columna alimento tiene un único valor (Feed1) y las columnas consumo y consumido presentan las mismas estadísticas, por lo que probablemente son la misma variable. Conviene comprobar que sean idénticas en todos los registros antes de eliminar una.
- El identificador de la vaca se obtiene de los dígitos del nombre del archivo. Si algún archivo tuviera números adicionales en el nombre, por ejemplo una copia, el identificador quedaría mal construido, por lo que se recomienda validar que todos los identificadores tengan el formato esperado y coincidan entre fuentes.

Validez de la variable de cola

Los datos no incluyen la hora en que cada vaca llega al área de espera, por lo que la cola no se puede medir de forma directa. Para aproximarla usamos el tiempo libre entre el fin de un ordeño y el inicio del siguiente en el mismo robot: si es de 2 minutos o menos, consideramos que la siguiente vaca probablemente estaba esperando. El tiempo libre más frecuente es de 0.4 a 0.5 minutos en los tres robots, lo que coincide con el tiempo mínimo que tarda el robot en cambiar de vaca y respalda el umbral elegido. Aun así, se trata de una aproximación que conviene validar con el socio formador y que depende de que estén registrados todos los ordeños de cada robot, como se explica en la sección de cobertura.

5.3 Resumen de problemas y tratamiento

La siguiente tabla resume los problemas encontrados, su magnitud y el tratamiento definido para la fase de preparación.

Cuadro 13: Resumen de problemas de calidad y su tratamiento.

Problema	Dimensión	Magnitud	Tratamiento
rcs_celulas_ml y usuario sin información	Completitud	100 % de nulos	Se eliminan, revisando antes las 2 filas con usuario
Registros sin robot asignado	Completitud	2 registros	Se eliminan, porque sin robot no se puede calcular la cola
Incidencias cuyo nulo significa que no ocurrieron	Completitud	84 % a 88 % de nulos	Se convierten en banderas binarias, sin imputar
programa_lavado y razon_desviacion	Completitud	94.37 % y 99.45 % de nulos	Se conservan como banderas de lavado y de desviación sin razón registrada
Nulos por cuarto y en mdi	Completitud	1.51 % a 3.94 % y 7.80 %	Se dejan como faltantes con una bandera, sin imputar
Traslapes en un mismo robot	Unicidad	2 registros	Se excluyen del cálculo del tiempo libre
Intervalo recortado a 24 h e intervalos en 0	Formato	2,845 intervalos mayores a 24 h y 403 en 0	El intervalo se calcula con fechas y se eliminan los intervalos de 0 min
Día y mes intercambiados en marzo a junio de 2025	Formato	Dataset completo	Se vuelven a leer las fechas con el día primero
Producción de 0 kg	Validez	165 registros	Se excluyen de la base limpia
Duraciones fuera de 1 a 30 min	Validez	39 registros	Se excluyen de la base limpia
Atípicos en variables sesgadas	Valores atípicos	0.56 % a 13.70 % según la variable	Se conservan; se usa IQR o logaritmo y banderas
Horas sin actividad en los 3 robots	Cobertura	948 h (3.05 %)	Se excluyen las ventanas de esas horas

Problema	Dimensión	Magnitud	Tratamiento
Historial solo de vacas actuales	Cobertura	Todo el periodo	Se documenta como limitación y se comparan proporciones en lugar de conteos
Diferencias entre concentrado y producción	Consistencia entre fuentes	203 contra 201 vacas; 1 año contra 3.5 años	El análisis conjunto se limita al periodo en común

Al aplicar los filtros de registros, la base limpia (S0) queda con 278,167 ordeños de 200 vacas en los 3 robots, lo que significa que se eliminan 600 registros, el 0.22 % del total. Es importante que todo el equipo trabaje con las mismas reglas: el proceso ETL de la entrega de Big Data usa un rango de duración de 0.5 a 30 minutos y conserva los ordeños de 0 kg, por lo que obtiene 278,729 registros. Se recomienda unificar ambos procesos con los criterios de este reporte.

5.4 Limitaciones

Aunque los problemas anteriores se pueden tratar, algunas limitaciones permanecen y deben tomarse en cuenta al interpretar los resultados:

- La cola se aproxima con el tiempo libre entre ordeños, ya que no hay registro de la llegada de las vacas al área de espera.
- El historial solo incluye a las vacas actuales, lo que subestima las colas en los primeros años del periodo.
- El ciclo de lactancia se infiere a partir de los periodos sin ordeño, y no existen registros de parto o secado para validarlo.
- No hay registros de lavados, fallas o mantenimientos de los robots, por lo que los paros se identifican de forma indirecta.
- No es posible distinguir a las vacas que llegan por su cuenta de las que son llevadas por el personal.
- El primer y el último mes del periodo (julio de 2022 y enero de 2026) están incompletos, por lo que se excluyen de las comparaciones mensuales.

5.5 Conclusiones

En general, los datos de producción de leche por sesión tienen una calidad adecuada para el objetivo del proyecto. No hay duplicados, las fechas y duraciones se pueden interpretar correctamente y los registros con valores inválidos representan menos del 1 % del total. La mayoría de los nulos tienen una explicación dentro del contexto del ordeño y se pueden manejar con banderas en lugar de eliminar información.

Los problemas que más afectan al proyecto no están en los valores individuales, sino en la cobertura de los datos: el historial solo incluye a las vacas actuales, la cola se mide de forma indirecta y el ciclo de lactancia se tiene que reconstruir. Estos puntos no impiden continuar con el proyecto, pero sí deben considerarse al interpretar los resultados, en particular cualquier tendencia de las colas a lo largo de los años. Para la fase de

preparación se recomienda trabajar con la base limpia S0, documentar cada filtro aplicado y validar con el socio formador tanto la definición de cola como los casos de secado que no se pudieron identificar.

6. Conclusiones generales

La fase de Data Understanding permitió reunir, describir, explorar y evaluar los datos del CAETEC. Los datos se consolidaron en tres DataFrames con trazabilidad por archivo y por vaca, y el dataset de producción de leche por sesión, con más de 278 mil ordeños de 201 vacas en tres robots, resultó suficiente y de calidad adecuada para estudiar la formación de colas.

La exploración confirmó que la ocurrencia de colas depende de la hora del día y de la ocupación de los robots, descartó un efecto del día de la semana y dejó abiertas hipótesis sobre la alimentación, el ciclo de lactancia y la persistencia de la cola. Las principales limitaciones son que la cola se mide de forma indirecta, que el historial solo incluye a las vacas actuales y que el ciclo de lactancia debe reconstruirse. Con los tratamientos definidos en el reporte de calidad, el proyecto puede avanzar a la fase de Data Preparation trabajando con la base limpia S0.