

Tecnológico de Monterrey

Tecnológico de Monterrey.

Inteligencia Artificial Avanzada para la Ciencia de Datos
"Reto CAETEC | Data Preparation"

Profesores:
Benjamín Valdés Aguirre
Eduardo Daniel Juárez Pineda

Jorge Armando Garzón Varela | A01707102
Santiago Alducin Villaseñor | A01707122
Sebastián Pérez García | A01707346
Roberto Serna Niño | A01709577
Kamila Jeannette Martinez Ibarra | A01711833

Fecha de entrega: 04 de noviembre de 2026

Índice

1 Introducción

- 1.1 Objetivo de la fase de Data Preparation
- 1.2 Objetivo del reporte
- 1.3 Contenido del reporte
- 1.4 Resumen del flujo de datos

2 Reporte de base lógica de inclusión y exclusión

- 2.1 Datos de partida
- 2.2 Evaluación de la correlación de las variables
- 2.3 Criterios de evaluación
- 2.4 Subconjuntos y muestreo
- 2.5 Datos incluidos y excluidos
- 2.6 Conclusiones

3 Reporte de limpieza de datos

- 3.1 Aplicación de las soluciones del reporte de calidad
- 3.2 Ruido y valores especiales
- 3.3 Cambios en las propuestas
- 3.4 Conclusiones

4 Reporte de construcción de datos

- 4.1 Definición de cola
- 4.2 Atributos derivados
- 4.3 Atributos que no se usan como predictores
- 4.4 Registros generados
- 4.5 Herramientas de preparación
- 4.6 Conclusiones

5 Reporte de integración de datos

- 5.1 Origen de los datos
- 5.2 Flujo de la integración

5.3 Llaves primarias

5.4 Panel de datos

5.5 Conclusiones

6 Reporte de formateo de datos

6.1 Ajustes de formato

6.2 Datasets finales

6.3 Conclusiones

7 Descripción de los datasets finales

7.1 Por qué se tienen dos datasets

7.2 Dataset de regresión

7.3 Dataset de serie de tiempo

7.4 Diccionario de variables

7.5 Bloques sin ordeños

7.6 Conclusiones

8 Conclusiones generales

1. Introducción

Para el análisis de colas de ordeño utilizamos datos del CAETEC sobre los tiempos de ordeña y la producción de las vacas en los robots de ordeño (VMS). Este documento corresponde a la tercera fase de la metodología CRISP-DM, la preparación de los datos (Data Preparation).

1.1 Objetivo de la fase de Data Preparation

El objetivo de esta fase es dejar los datos listos para el modelado. Para ello se decide qué datos se usan y cuáles se excluyen, se corrigen los problemas de calidad detectados en la fase anterior, se construyen los atributos derivados, se integran las tablas y se da a los datos el formato que requiere el algoritmo. El resultado son dos datasets finales con la misma variable objetivo: uno para regresión (`dataset_final_regresion.parquet`, con 132,028 bloques de 30 minutos y 22 columnas) y otro de serie de tiempo (`dataset_final_serie_tiempo.parquet`, con 179,850 bloques y 24 columnas).

1.2 Objetivo del reporte

Este reporte reúne en un solo documento los cinco entregables de la fase, de modo que cada decisión de preparación quede justificada y cualquier integrante del equipo pueda reproducir el proceso.

1.3 Contenido del reporte

- **Base lógica de inclusión y exclusión (sección 2):** define el nivel de análisis, los criterios para elegir datos y los datos que se incluyen y excluyen.
- **Limpieza de datos (sección 3):** aplica las soluciones del reporte de calidad y define cómo se manejan el ruido y los valores especiales.
- **Construcción de datos (sección 4):** describe los atributos derivados, la decisión de no generar registros y las herramientas utilizadas.
- **Integración de datos (sección 5):** explica cómo se unen las tablas, sus llaves y el panel de datos resultante.
- **Formateo de datos (sección 6):** detalla los ajustes de formato necesarios para scikit-learn.
- **Descripción de los datasets finales (sección 7):** presenta los dos datasets resultantes, su diccionario de variables y el tratamiento de los bloques sin ordeños.

1.4 Resumen del flujo de datos

El Cuadro 1 resume cuántos registros quedan después de cada etapa. Los detalles de cada paso se encuentran en las secciones siguientes. El dataset de serie de tiempo parte de la malla completa de bloques de cada robot, incluidos los que no tienen ordeños, y tiene 179,850 filas y 24 columnas (sección 7).

Cuadro 1: Flujo de los datos durante la preparación.

Etapa	**Registros**
Ordeños de entrada (`prodLecheSesion`)	278,767
Sin robot asignado	$-2 \rightarrow$ 278,765
Traslape en el mismo robot	$-1 \rightarrow$ 278,764
Sin siguiente ordeño (no se puede calcular el tiempo libre)	$-3 \rightarrow$ 278,761
Bloques de 30 min por robot (`df_sistema`)	136,630
Días con operación incompleta	$-50 \rightarrow$ 136,580
Meses incompletos (julio 2022 y enero 2026)	$-4{,}552 \rightarrow$ 132,028
Dataset de regresión	**132,028 $\times$ 22**

2. Reporte de base lógica de inclusión y exclusión

Esta sección explica qué datos se usan para el modelado y cuáles se descartan. Se trabaja con la tabla de robot por bloque de 30 minutos, sin muestreo, porque la cola es un fenómeno del sistema y no de cada vaca.

2.1 Datos de partida

La fuente es `produccion_leche_sesion`, exportada por el notebook de Data Understanding: 278,767 ordeños y 49 columnas de los tres robots (VMS 1, VMS 2 y VMS 3), del 13 de julio de 2022 al 28 de enero de 2026.

La variable objetivo es `posible_cola`, que vale 1 si el siguiente ordeño del mismo robot empieza 2 minutos o menos después de que termina el anterior. El 53.7 % de los ordeños cumple esta condición.

2.2 Evaluación de la correlación de las variables

Para poder correlacionar las variables de texto se convirtieron a números: `patada`, `incompleto` y `pezones_no_encotnrados` pasaron a número de pezones afectados (0 a 4) y `destino_leche` pasó a una variable binaria (0 = Tanque, 1 = desviada).

A nivel ordeño ninguna variable explica la cola. Los coeficientes de Pearson quedan entre -0.09 y 0.07, salvo `desviacion_leche` (-0.26) y `tiempo_libre_min` (-0.48). Esta última no es válida como predictora porque con ella se define la cola.

A nivel bloque sí aparecen relaciones. Tres variables de ocupación superan $r = 0.5$ (entre 0.64 y 0.65): `pct_ocupacion_robot` (parte del bloque en que el robot estuvo ordeñando), `duracion_total_min` (minutos de ordeño en el bloque) y `total_ordenios` (número de ordeños del bloque). Por eso se agrupó por robot y bloque de 30 minutos: la cola depende de cuántas vacas quieren usar el robot al mismo tiempo (Figura 1).

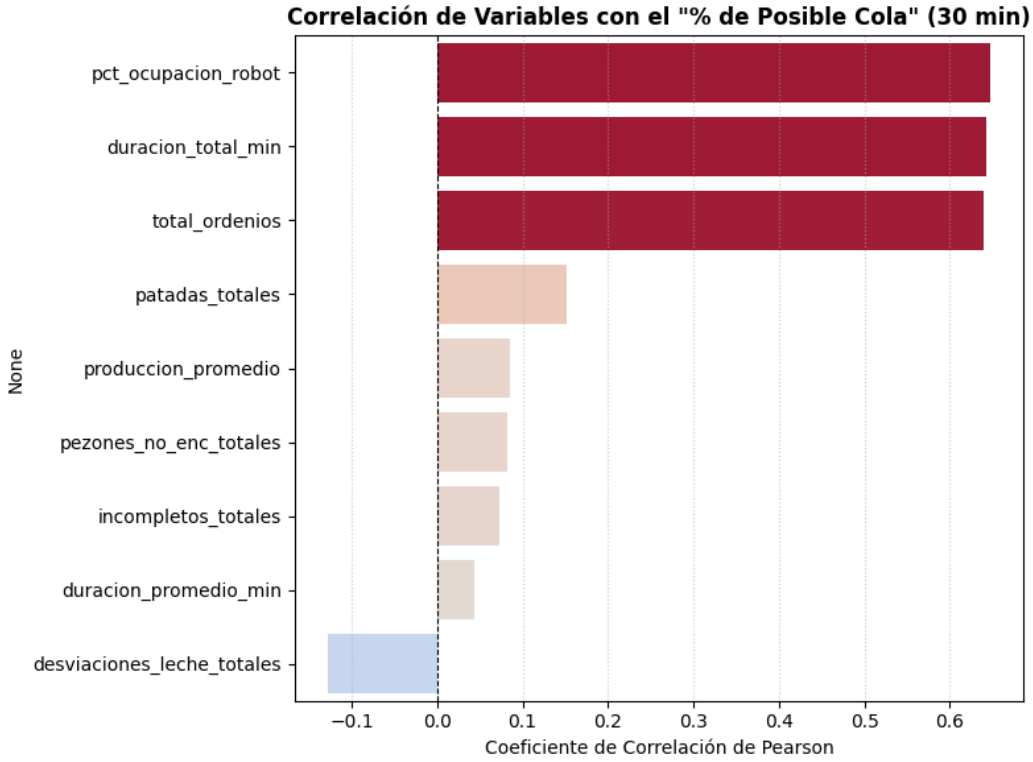


Figura 1: Correlación de las variables con el porcentaje de posible cola por bloque de 30 minutos.

Las variables temporales muestran una correlación lineal cercana a 0, pero el porcentaje de cola sí cambia por hora: baja a 28.7 % a las 4 h y a 33.4 % a las 20 h (Figura 2). Pearson solo mide relaciones lineales, por eso estas variables se incluyen aunque su coeficiente sea bajo. La temporada solo muestra una correlación pequeña con la cola en invierno, sin evidencia suficiente para conclusiones más firmes.

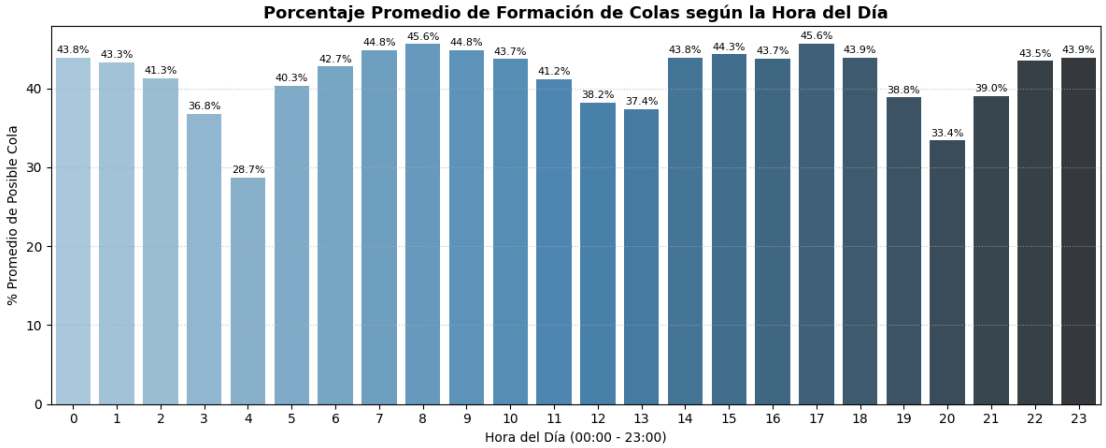


Figura 2: Porcentaje promedio de formación de colas según la hora del día.

2.3 Criterios de evaluación

El Cuadro 2 muestra las reglas aplicadas a cada variable y registro.

Cuadro 2: Criterios de inclusión y exclusión.

Criterio	**Aplicación**	**Umbral o regla**
Relevancia	Correlación de Pearson de cada variable con la cola, por bloques de 30 minutos	Alta: $\|r\| \geq 0.5$. Baja: $0.1 \leq \|r\| < 0.5$. Se descartan las de $\|r\| < 0.1$
Relevancia (variables temporales)	Patrón del porcentaje de cola por hora del día y por temporada	Se incluyen aunque la correlación lineal sea baja, porque el patrón no es lineal
Calidad	Completitud de cada variable y de cada día	Se excluyen las variables casi vacías y los días con menos del 50 % de los ordeños de un día normal
Fuga de información	Si la variable forma parte de la definición de la cola	Se excluye como predictora cualquier variable con la que se calcula la cola
Restricciones técnicas	Tipo de dato y tamaño	La correlación requiere variables numéricas y el dataset debe caber en la memoria de Colab

2.4 Subconjuntos y muestreo

El Cuadro 3 resume cada revisión, su resultado y la decisión tomada.

Cuadro 3: Subconjuntos y muestreo.

Revisión	Resultado	Decisión
Cobertura por robot y mes	Los 3 robots tienen registros todos los días entre el 13 de julio de 2022 y el 28 de enero de 2026. Julio de 2022 y enero de 2026 están incompletos	Se excluyen esos dos meses (4,552 bloques, 3.3 %)
Días con operación incompleta	7 días con menos del 50 % de los ordeños de un día normal (VMS 1: 2, VMS 2: 1, VMS 3: 4), equivalentes a 50 bloques	Se excluyen: los registros faltantes inflan el tiempo libre y marcan falsamente “sin cola”
Bloques con 1 ordeño	48,844 bloques (35.8 %), con 12.7 % de cola y desviación estándar de 0.332, casi igual a la de los bloques de 2 ordeños (0.320)	Se conservan: excluirlos subiría la cola promedio de 41.8 % a 58.1 %
Horas con lavado del robot	Los picos de lavado a las 4 h y a las 20 h coinciden con las horas de menos cola (28.7 % y 33.4 %)	Se conservan y se marcan como atributo
Muestreo por tamaño	El dataset ocupa 42.0 MB en memoria	No se requiere
Muestreo por balance	53.7 % de los ordeños con posible cola	No se requiere

Como los datos son una serie de tiempo, no se usa un k-fold aleatorio: mezclaría los bloques y el modelo podría entrenar con 2025 para predecir 2023. En su lugar se usa `TimeSeriesSplit` con 5 folds, donde cada uno entrena con todo lo anterior y prueba con el periodo siguiente. Con 132,028 bloques, cada fold de prueba tiene 22,004 bloques.

Para la fase de modelado se identificaron tres subconjuntos candidatos para analizar por separado: por robot, por periodo (los ordeños mensuales de VMS 1 pasaron de unos 1,000 en 2022 a 3,900 en 2025) y por nivel de tráfico del bloque.

2.5 Datos incluidos y excluidos

Datos incluidos

Cuadro 4: Datos incluidos.

Dato	Tipo	Razón
Bloques de robot $\times$ 30 min	Nivel de análisis	A nivel bloque aparecen relaciones de hasta 0.65 y es el nivel que define la cola
`pct_posible_cola`	Variable objetivo	Mide la cola como porcentaje de ordeños con cola en el bloque
`patadas_totales`	Baja relación	$r = 0.15$. Las patadas alargan el ordeño y pueden retrasar al resto

Dato	Tipo	Razón
`produccion_promedio`	Baja relación	$r = 0.09$. Mayor producción alarga el ordeño
`desviaciones_leche_totales`	Baja relación	$r = -0.13$. Es la única relación negativa
Hora, día de la semana y temporada	Temporales	El porcentaje de cola cambia por hora y es algo mayor en invierno
`ms` y `bloque_tiempo`	Identificadores	Necesarios para los subconjuntos y para `TimeSeriesSplit`
Bloques con un ordeño y con lavado	Registros	Representan periodos tranquilos; excluirlos sesgaría el objetivo. El lavado puede explicar la cola y se marca como atributo
Atributos del bloque anterior, composición por lactancia, alimentación y tamaño del hato	Contexto y algoritmo	Se construyen en la sección 4. Los del bloque anterior permiten predecir sin usar información del mismo bloque

Datos excluidos

Cuadro 5: Datos excluidos.

Dato	Razón
7 días con operación incompleta y los meses de julio de 2022 y enero de 2026	Los registros faltantes inflan el tiempo libre y marcan falsamente "sin cola"; los meses de los extremos del historial no están completos
Variables por cuarto: `produccion_*`, `media_flujo_*`, `flujo_maximo_*`, `sangre_*`, `conductividad_*`, `contador_*`	$\|r\| < 0.1$ con la cola y no describen la operación del robot
`incompletos_totales`, `pezones_no_enc_totales`, `duracion_promedio_min`	$\|r\| < 0.1$ a nivel bloque y sin significado operativo
`tiempo_libre_min`	Con ella se define `posible_cola`; su correlación de -0.48 es por construcción
`pct_ocupacion_robot`, `duracion_total_min`, `total_ordenios`, `ordenios_otros_robots`	Se calculan con los mismos ordeños que el objetivo: si el robot estuvo ocupado casi todo el bloque, los huecos entre vacas son de 2 minutos o menos por construcción. Su r de 0.64 a 0.65 no indica una relación útil sino fuga de información
`estado_md_pezon`, `razon_desviacion` y `programa_lavado` como columnas por ordeño	Casi vacías. El lavado se conserva resumido en `hubo_lavado`
`rcs_celulas_ml`, `usuario`	No aportan información

2.6 Conclusiones

La cola es un fenómeno del sistema y no de cada vaca: solo aparece al medir bloques de tiempo y depende sobre todo de qué tan ocupado esté el robot. La selección conserva el 96.6 % de los bloques y descarta solo variables sin poder explicativo o registros incompletos, por lo que no se requiere muestreo. Además, se incluyeron patrones temporales, como las horas de lavado y las variaciones por hora, y se definió una validación con `TimeSeriesSplit` que respeta el orden en el tiempo.

---

3. Reporte de limpieza de datos

Este reporte documenta la aplicación de las soluciones propuestas en el reporte de calidad y el manejo del ruido y los valores especiales. La limpieza se hizo sobre los DataFrames `prodLecheSesion` y `concentradoConsumido`.

El criterio general es corregir los errores de integridad, auditar las anomalías y conservar, con una bandera, los eventos reales atípicos. El flujo de registros se muestra en el Cuadro 1.

3.1 Aplicación de las soluciones del reporte de calidad

El número de la primera columna corresponde a la numeración del reporte de calidad.

Cuadro 6: Soluciones aplicadas.

#	Problema	Solución aplicada	Resultado
1.a, 1.b	`rcs_celulas_ml` vacía y `usuario` casi vacía	Se eliminan ambas. Los 2 registros con `usuario` se van con los de `ms` nulo (5.b)	-2 columnas
1.c	`programa_lavado` con un solo valor	Pasa a booleana (“Local Aclarado” = verdadero, nulo = falso). A nivel bloque se resume en `hubo_lavado`	Sin nulos
1.d, 5.a	`razon_desviacion` casi vacía y desviaciones sin explicación	Si el destino no es Tanque y no hay razón, se escribe “sin razón registrada”	Cubre cerca del 90 % de las 15,730 desviaciones
1.e	`consumido` duplica a `consumo`	Se elimina `consumido`	-1 columna
2.a, 2.b	Nulos por cuarto (1.5 a 3.9 %) y en `mdi` (7.8 %)	Se dejan como NaN, sin imputar	Se conservan
2.c	Ceros imposibles en conductividad y flujo medio	Los 0 se reemplazan por NaN	150,049 celdas (sección 3.2)
3.a, 3.b	`patada`, `incompleto` y `pezones_no_encotnrados` con 84 a 88 % de nulos	Nulo significa “no ocurrió”. Se crean conteos `*_cant` (0 a 4) y una columna por cuarto (`_di`, `_dd`, `_ti`, `_td`). “Todos” cuenta como 4	Sin pérdida de filas

#	Problema	Solución aplicada	Resultado
4.a	Ordeños de 0 kg	Se conservan	165 registros
4.b	Duración menor a 1 o mayor a 30 min	Bandera `ordenio_anomalo`	39 registros
4.c	Producción total contra suma de cuartos	Bandera `desbalance_produccion` (tolerancia de 0.1 kg)	9 registros
4.d	`mdi` sesgado, con 13.7 % de atípicos	Sin modificar	Se conserva
5.b	Registros sin robot	Se eliminan	2 registros
5.c	Traslapes en un mismo robot	Se conserva el ordeño más temprano y se excluye el que choca. Los excluidos se guardan en `traslapes`	1 excluido, 0 restantes en la auditoría
6.b	Primer y último mes incompletos	Se excluyen julio de 2022 y enero de 2026	4,552 bloques (3.3 %)
6.e	Vacas con historial muy corto	`produccion_clean_strict`, solo con vacas de 30 días o más de historial	267,023 ordeños (se usa en análisis por vaca, no en `df_sistema`)
6.a	Historial solo de vacas actuales	No se corrige; se documenta como limitación	—
6.h	Lactancia inferida	Se toma de S0 y se une por vaca, robot y hora	94.2 % con etapa conocida

Además, se excluyeron los días con operación incompleta (menos del 50 % de la mediana móvil de 30 días): 7 días, equivalentes a 50 bloques (0.04 %).

3.2 Ruido y valores especiales

Se definió **ruido** como lo que distorsiona la medición sin reflejar el fenómeno (errores de sensor o de registro), y **valor especial** como un dato válido con significado propio que no debe tratarse como faltante.

Ruido

Cuadro 7: Ruido y su manejo.

Tipo	Criterio	Manejo	Magnitud
Ceros imposibles	Conductividad o flujo medio igual a 0	Se reemplazan por NaN	Conductividad: 115,372 (78,583 en TD). Flujo medio: 34,677
Robot faltante	`ms` nulo	Se elimina	2
Traslape	Inicia antes de que termine el anterior	Se excluye y se audita	1
Duración atípica	Menor a 1 min o mayor a 30 min	Bandera, se conserva	39

Tipo	Criterio	Manejo	Magnitud
Desbalance entre cuartos	Diferencia mayor a 0.1 kg	Bandera, se conserva	9
Flujo irreal	Mayor a 7 kg/min	Se conserva para revisión	1
Día incompleto	Menos del 50 % de la mediana móvil	Se excluyen sus bloques	7 días

Valores especiales

Cuadro 8: Valores especiales y su manejo.

Tipo	Interpretación	Manejo	Magnitud
Nulo en incidencias	El evento no ocurrió	Conteo y banderas por cuarto	84 a 88 % de nulos
Desviación sin razón	Vacío real de información	“sin razón registrada”	∼90 % de las desviaciones
Producción de 0 kg	Ordeño fallido, pero la vaca ocupó el robot	Se conserva	165
`mdi` alto	Sesgo natural del índice, no es error	Se conserva sin transformar	13.7 %
Bloques de 1 ordeño	Periodos de baja actividad	Se conservan. Su desviación (0.332) es casi igual a la de bloques de 2 ordeños (0.320); quitarlos sesgaría el objetivo hacia periodos con más cola	35.8 % de los bloques
Lactancia desconocida	Sin etapa inferible	Columna `sin_etapa` = 1 y proporciones en 0	9,010 bloques

3.3 Cambios en las propuestas

- Los ordeños de 0 kg y las duraciones atípicas **se conservan** con bandera. El reporte de calidad proponía excluirlos de la base limpia.
- En lugar de `hubo_patada`, `hubo_incompleto` y similares, se crearon conteos `*_cant` y columnas por cuarto, que contienen la misma información y más.
- La revisión de la propuesta 4.c se hizo comparando el total contra la suma de cuartos en todos los ordeños, no solo en los de más de 40 kg.

3.4 Conclusiones

La limpieza aplicó las soluciones del reporte de calidad sobre los problemas de columnas vacías, nulos, ceros imposibles, incidencias, inconsistencias entre columnas y cobertura, con un costo bajo en registros (6 ordeños eliminados de 278,767). Los valores atípicos que representan eventos reales se conservaron con banderas para no perder información sobre la ocupación del robot.

Quedan algunas propuestas sin aplicar (banderas faltantes, horas sin actividad, integración de `df_consolidado`) y un criterio por unificar sobre los ordeños de 0 kg. Con eso resuelto, la base queda lista para el resto de Data Preparation.

4. Reporte de construcción de datos

Construir los datos consiste en definir y calcular atributos que no venían en el dataset original, pero que son importantes para el proyecto. Como el objetivo está relacionado con las colas, algunos atributos sirven para calcular la formación de colas, otros para explicar su aparición y otros para entender el uso de los robots por parte de las vacas. El trabajo previo de Data Understanding permitió reutilizar varios de ellos.

Los atributos se construyen primero a nivel ordeño sobre `produccion_clean`, es decir, con los datos ya limpios, y después se agregan por robot y bloque de 30 minutos en `df_sistema`.

4.1 Definición de cola

El dataset de modelado usa `posible_cola`: un ordeño tiene posible cola si el siguiente ordeño del mismo robot empieza 2 minutos o menos después de que termina. El umbral se apoya en que el tiempo libre más frecuente es de 0.4 a 0.5 minutos, que corresponde al cambio de vaca. La variable `entro_en_cola`, definida en Data Understanding con episodios de cola, se usó solo en la exploración.

4.2 Atributos derivados

Los atributos se dividen en dos grupos. Las **transformaciones directas** extraen componentes de una columna existente, como la hora, el día de la semana y la temporada a partir de `hora_inicio`, lo que permite capturar patrones temporales y estacionales. Los **atributos calculados** se infieren con operaciones sobre una o más columnas, como el porcentaje de cola, la ocupación del bloque anterior o la etapa de lactancia. El Cuadro 9 los lista.

Cuadro 9: Atributos derivados.

Atributo	Nivel	Descripción y cálculo
`tiempo_libre_min`	Ordeño	Minutos que el robot quedó libre: inicio del siguiente ordeño del mismo robot menos el fin del ordeño (inicio más duración)
`posible_cola`	Ordeño	La siguiente vaca entró casi de inmediato, por lo que probablemente esperaba: `tiempo_libre_min` ≤ 2 min
`bloque_tiempo`	Ordeño	Bloque de 30 minutos en que empezó el ordeño (`hora_inicio` redondeada hacia abajo)
`pct_cola_bloque`	Ordeño	Promedio de `posible_cola` por robot y bloque, por 100

Atributo	Nivel	Descripción y cálculo
`min_desde_alimento`	Ordeño y bloque	Minutos desde la última alimentación (7:30 o 14:30 h)
`desviacion_leche`	Ordeño	1 si `destino_leche` es distinto de Tanque, 0 si es Tanque, nulo si no hay destino
`ordenios_con_lavado`	Bloque	Suma de `programa_lavado` en el bloque
`hubo_lavado`	Bloque	1 si `ordenios_con_lavado` es mayor que 0
`pct_primer_parto`	Bloque	Proporción de ordeños de vacas probablemente de primer parto, solo con grupo de vaca conocido
`pct_fresca`, `pct_alta`, `pct_baja`, `pct_extendida`	Bloque	Proporción de ordeños del bloque en cada etapa de lactancia, solo con etapa conocida
`hora`	Bloque	Hora del día del bloque (0 a 23)
`dia_semana`	Bloque	Día de la semana del bloque (0 = lunes)
`temporada`	Bloque	Diciembre a febrero, invierno; marzo a mayo, primavera; junio a agosto, verano; septiembre a noviembre, otoño
`vacas_activas_dia`	Bloque	Tamaño del hato ese día: vacas distintas ordeñadas en los tres robots
`ordenios_otros_robots`	Bloque	Ordeños del bloque en los tres robots menos los del robot
`ocupacion_bloque_anterior`	Bloque	Ocupación del robot en los 30 minutos previos (`shift(1)` sobre la malla completa de bloques)
`ordenios_bloque_anterior`	Bloque	Ordeños del robot en los 30 minutos previos
`pct_cola_bloque_anterior`	Bloque	Proporción de ordeños con posible cola en los 30 minutos previos; 0 si ese bloque no tuvo ordeños

El tiempo desde la alimentación combina el horario de alimentación con los registros de ordeño. Los atributos del bloque anterior se calculan sobre una malla completa de bloques de cada robot, incluidos los que no tuvieron ordeños, de modo que el rezago siempre corresponde a los 30 minutos previos.

4.3 Atributos que no se usan como predictores

`pct_ocupacion_robot`, `duracion_total_min` y `total_ordenios` se calculan con los mismos ordeños que el objetivo, así que usarlos como entrada produciría fuga de información. Por eso se construyen sus versiones del bloque anterior, que sí estarían disponibles al momento de predecir. Las columnas originales se conservan en `df_sistema_sel` y se excluyen en el dataset de regresión (sección 7).

4.4 Registros generados

No se generaron registros nuevos. Esta estrategia suele usarse cuando hay pocos datos, pero aquí no es necesaria porque se cuenta con más de 278 mil ordeños y 132 mil bloques, y en una serie de tiempo un registro prototípico no aportaría información verídica para predecir la cola.

4.5 Herramientas de preparación

- **pandas y numpy en Google Colab** para construir los atributos: agregaciones con `groupby().agg()` y rezagos con `groupby().shift()`.
- **scikit-learn** solo para `TimeSeriesSplit` en la validación.
- **Parquet** en `Datos/Procesado` para guardar los resultados, igual que en Data Understanding.

Se mantienen las mismas herramientas de las fases anteriores porque el volumen de datos es pequeño y no se requiere otra.

4.6 Conclusiones

La construcción reunió en una sola sección los atributos que antes estaban repartidos entre los notebooks, incluido el de lavado que había quedado pendiente en la base lógica. Se eligió una sola definición de cola y se reemplazaron las variables que causaban fuga de información por sus versiones del bloque anterior. El resultado es un conjunto de atributos temporales, de ocupación y de historial que describe la dinámica del sistema de ordeño.

5. Reporte de integración de datos

Integrar los datos consiste en combinar información de varias tablas para crear nuevos registros o valores. La integración se hizo en dos niveles: primero se unieron los archivos individuales de cada vaca en tablas consolidadas (unión vertical) y después se unieron tablas por llave común para construir los subconjuntos de análisis y el dataset de modelado.

El resultado es un panel de datos: las mismas entidades (vacas y robots) observadas a lo largo del tiempo. Por eso todas las llaves combinan un identificador de entidad (`id_vaca` o `ms`) con una marca de tiempo en distinta granularidad.

5.1 Origen de los datos

Los datos provienen de los registros de los robots de ordeño VMS del CAETEC. Cada archivo contiene los registros de una sola vaca y el número de la vaca solo aparece en el nombre del archivo.

Cuadro 10: Fuentes de la integración.

Fuente	Formato	Periodo	Tabla resultante
Archivos de ordeño de marzo a junio de 2025	CSV, uno por vaca	Marzo a junio de 2025	`df_consolidado`: 7,249 registros y 36 columnas

Fuente	Formato	Periodo	Tabla resultante
Producciones de leche por sesión (histórico)	Excel, uno por vaca	13 de julio de 2022 al 28 de enero de 2026	`prodLecheSesion`: 278,767 ordeños y 49 columnas
`mapeo_id_vaca.csv`	CSV	No aplica	Correspondencia entre el número original de la vaca y su identificador anonimizado (`VACA_###`)

`prodLecheSesion` es la fuente principal: de ella salen la base limpia S0, los subconjuntos S1 a S5 y el dataset de modelado. `df_consolidado` se conserva como tabla de consulta y no se une con el resto.

5.2 Flujo de la integración

1. **Lectura y etiquetado:** cada archivo se leyó con nombres de columna fijos y se le agregó `id_vaca`, tomada del nombre del archivo, y `origen_archivo`.
2. **Anonimización de la llave:** el número original de cada vaca se reemplazó por `VACA_###` con el mapeo de `mapeo_id_vaca.csv`. El mismo mapeo se aplica a todas las tablas, por lo que `id_vaca` sigue sirviendo como llave.
3. **Unión vertical:** los archivos de cada tipo se apilaron con `pd.concat`, ya que comparten el mismo esquema.
4. **Tipos y verificación de la llave:** se convirtieron la fecha y la duración y se revisaron duplicados y solapamientos. Esto respalda el uso de `id_vaca` + `ms` + `hora_inicio` como llave del ordeño.
5. **Subconjuntos por llave común:** a partir de S0 se generaron los subconjuntos S1 a S5 con agregaciones, uniones y filtros.
6. **Exportación:** las tablas se guardaron en parquet en `Datos/Procesado`, de donde las lee el notebook de preparación.
7. **Integración para el modelado:** los ordeños depurados (`produccion_clean`) se unieron con S0 para traer el ciclo de lactancia, se agregaron por robot y bloque de 30 minutos en `df_sistema` y se unieron con la cobertura diaria (`diario`) para filtrar los días incompletos.

El Cuadro 11 resume cada unión por llave común.

Cuadro 11: Uniones por llave común.

Unión	Llave	Operación	Resultado
Archivos por vaca → `prodLecheSesion`	`id_vaca` (nombre del archivo)	Unión vertical con `pd.concat`	278,767 ordeños de los tres robots
Ciclo de lactancia → S0	Índice del ordeño	Alineación con `reindex`	Días en leche, etapa, grupo de vaca e indicadores `es_*`
S3 → S0	`id_episodio`	`map`	Etiquetas de entrada en cola por ordeño

Unión	Llave	Operación	Resultado
S0 → S1	`ms` + `ventana`	Agregación sobre la malla completa	180,837 ventanas de 30 min, incluidas las sin ordeños
Vacas activas por día → S1 y `df_sistema`	`fecha`	`map`	`vacas_activas_dia`
S0 → S4	`id_vaca` + `fecha`	`groupby`	114,910 registros vaca-día
S0 → `produccion_clean`	`id_vaca` + `ms` + `hora_inicio`	`join` izquierdo	Ciclo de lactancia en los ordeños depurados; 94.2 % con etapa conocida
`produccion_clean` → `df_sistema`	`ms` + `bloque_tiempo`	`groupby`	136,630 bloques
`diario` → `df_sistema_sel`	`ms` + `dia`	`merge` izquierdo	Marca `dia_completo`; 132,028 bloques finales

5.3 Llaves primarias

Cada tabla tiene una llave primaria que identifica de forma única a cada registro, y esta depende de su unidad de análisis (Cuadro 12).

Cuadro 12: Llaves primarias por tabla.

Tabla	Unidad de registro	Llave primaria	Origen
`prodLecheSesion` y S0	Ordeño	`id_vaca` + `ms` + `hora_inicio`	Tabla base
`df_consolidado`	Ordeño, marzo a junio de 2025	`id_vaca` + `hora_inicio`	Solo consulta
S1	Robot × ventana de 30 min	`ms` + `ventana`	Agrega S0
S2 y S5	Ordeño con días en leche conocidos	`id_vaca` + `ms` + `hora_inicio`	Filtros de S0 y S2
S3	Episodio de cola	`id_episodio`	Agrega S0
S4	Vaca × día	`id_vaca` + `fecha`	Agrega S0
`produccion_clean`	Ordeño depurado	`id_vaca` + `ms` + `hora_inicio`	Se une con S0
`diario`	Robot × día	`ms` + `dia`	Cuenta ordeños
`df_sistema` y `df_sistema_sel`	Robot × bloque de 30 min	`ms` + `bloque_tiempo`	Agrega `produccion_clean`

Las dos llaves que conectan las tablas son `id_vaca`, a nivel vaca, y `ms` junto con el tiempo, a nivel robot. Las tablas a nivel ordeño comparten la misma llave y se pueden unir directamente; las agregadas se obtienen redondeando `hora_inicio` a la granularidad de la tabla.

5.4 Panel de datos

A nivel vaca (S0, S2 y S4) el panel no está balanceado, porque las vacas entran y salen del hato y tienen periodos de secado sin ordeños. A nivel robot, S1 es un panel prácticamente balanceado: se construyó con una malla completa de los tres robots por todas las ventanas de 30 minutos, así que incluye las ventanas sin ordeños. En `df_sistema` se usó la misma malla para calcular los atributos del bloque anterior.

5.5 Conclusiones

La integración unió los archivos de cada vaca en una sola tabla de ordeños y, a partir de ella, construyó los subconjuntos y el dataset de modelado con llaves formadas por la vaca o el robot y el tiempo. La llave `id_vaca` + `ms` + `hora_inicio` identifica cada ordeño y el resto de las tablas se derivan de ella al cambiar la granularidad. Así se pasa del nivel ordeño al nivel robot por bloque de 30 minutos, que es el que usa el modelo, sin perder la trazabilidad hacia el registro original.

---

6. Reporte de formateo de datos

Formatear los datos es la última actividad de la preparación: consiste en ajustar el formato y las dimensiones de los datos para que puedan usarse en el modelo. En este caso se ajustó `df_sistema_sel` para que scikit-learn lo procese sin errores, sin cambiar el significado de los datos.

6.1 Ajustes de formato

- **Tipos de datos:** las columnas `Int64` de pandas, que admiten nulos, se convirtieron al tipo nativo `int64` para evitar problemas de compatibilidad con scikit-learn.
- **Valores faltantes en lactancia:** 9,010 bloques no tenían etapa de lactancia conocida. En lugar de descartarlos, se agregó la columna indicadora `sin_etapa` (1 en esos bloques) y se rellenaron con 0 las cinco proporciones de lactancia. Así se conservan las observaciones y el modelo puede distinguir el dato desconocido.
- **Orden cronológico:** los registros se ordenaron por `bloque_tiempo` y `ms`. Este orden es necesario para `TimeSeriesSplit` y para que los valores del bloque anterior sean coherentes.
- **Orden de las columnas:** primero los identificadores, después las variables de entrada y al final la variable objetivo.

El resultado, con 132,028 bloques y 29 columnas, se guardó en `df_sistema_fromateado.parquet`, dentro de `Datos/Procesado`.

6.2 Datasets finales

Del dataset formateado se excluyen siete columnas para obtener el dataset de regresión: `incompletos_totales`, `pezones_no_enc_totales` y `duracion_promedio_min` (con $|r| < 0.1$ respecto a la cola), y `total_ordenios`, `duracion_total_min`, `pct_ocupacion_robot` y `ordenios_otros_robots` (fuga de información, sección 2.5). Las variables del bloque anterior se conservan y su uso se decide en el modelado.

El dataset de regresión tiene 132,028 filas y 22 columnas y se guarda en `dataset_final_regresion.parquet`. El de serie de tiempo conserva los intervalos continuos y las cuatro variables mecánicas, y se guarda en `dataset_final_serie_tiempo.parquet`. Ninguno está normalizado: el escalado se aplicará en el modelado, ajustándolo solo con los datos de entrenamiento de cada fold para no filtrar información del periodo de prueba. La columna `temporada` se conserva como texto. La sección 7 describe ambos datasets.

6.3 Conclusiones

El formateo deja los datos en una estructura limpia y ordenada para empezar el entrenamiento: tipos compatibles con scikit-learn, sin valores nulos, en orden cronológico y con los identificadores, las entradas y el objetivo claramente separados. Junto con las actividades anteriores, termina de definir los atributos del modelo y deja el dataset listo para la fase de modelado.

---

7. Descripción de los datasets finales

Como resultado de la fase de preparación se construyeron dos datasets a partir del mismo historial de ordeños, para estudiar la posible formación de colas por robot y por intervalos de 30 minutos. Comparten la variable objetivo `pct_posible_cola`, pero usan distintas entradas y distinta cobertura de bloques según el análisis que se quiera hacer.

7.1 Por qué se tienen dos datasets

El **dataset de regresión** organiza los bloques observados para analizar la relación de la posible cola con el calendario, la composición de lactancia, las incidencias y el estado del bloque anterior. Excluye cuatro variables mecánicas del mismo bloque, cuya relación con la etiqueta es directa por construcción y puede dominar el ajuste.

El **dataset de serie de tiempo** conserva intervalos regulares de 30 minutos por robot, incluidos los que no tienen ordeños registrados. Recupera las variables mecánicas para describir la evolución de la actividad y permite construir secuencias, estudiar patrones temporales y preparar modelos de pronóstico. Los rezagos se crearán en el modelado según la ventana elegida.

Cuadro 13: Comparación de los datasets finales.

Característica	Regresión	Serie de tiempo
Archivo	`dataset_final_regresion.parquet`	`dataset_final_serie_tiempo.parquet`
Filas y columnas	132,028 filas y 22 columnas	179,850 filas y 24 columnas
Periodo global	1 de agosto de 2022 al 31 de diciembre de 2025	1 de agosto de 2022 al 31 de diciembre de 2025
Robots	VMS 1, VMS 2 y VMS 3	VMS 1, VMS 2 y VMS 3
Cobertura temporal	Bloques observados seleccionados; existen huecos	Bloques continuos de tiempo, para no dañar la secuencialidad
Rezagos exportados	Tres variables del bloque anterior	Ninguno
Variables mecánicas	Se excluyen cuatro del bloque actual	Se conservan las cuatro

Cada fila corresponde a un robot y un bloque, y la pareja `ms` y `bloque_tiempo` identifica de manera única las observaciones en ambos archivos. Se comparten 19 columnas. La serie contiene 47,792 bloques sin ordeños y 30 bloques observados adicionales frente al dataset de regresión.

7.2 Dataset de regresión

Contiene 132,028 bloques observados y 22 columnas, sin valores nulos. Parte de los datos seleccionados y formateados: excluye meses incompletos, días con cobertura insuficiente y bloques por debajo del mínimo de ordeños configurado. No se generan filas para cubrir sus huecos temporales.

Se utiliza para ajustar modelos de regresión de `pct_posible_cola` y estudiar asociaciones entre las entradas y la posible cola. Los rezagos corresponden al intervalo previo real de 30 minutos de cada robot, calculado antes de seleccionar las filas. El archivo no contiene variables normalizadas.

7.3 Dataset de serie de tiempo

Contiene 179,850 bloques y 24 columnas: 132,058 bloques con ordeños registrados y 47,792 sin ordeños, que equivalen al 26.57 % de las filas. Los intervalos son consecutivos cada 30 minutos para cada robot y no se exportan rezagos.

La malla de VMS 3 inicia el 1 de agosto de 2022 a las 00:00, la de VMS 1 a las 01:00 y la de VMS 2 a las 02:00. Las tres terminan el 31 de diciembre de 2025 a las 23:30. Se mantienen los meses excluidos, pero no se eliminan días ni bloques por baja actividad, para conservar la continuidad dentro del historial de cada robot.

Este dataset se utiliza para analizar la dinámica temporal, la estacionalidad y la actividad de cada robot. Para pronosticar, la etiqueta debe ubicarse en el instante futuro elegido y las entradas deben construirse únicamente con información disponible al momento de predecir.

7.4 Diccionario de variables

En la columna **Dataset**, R indica que la variable está en el dataset de regresión y S que está en el de serie de tiempo.

Cuadro 14: Diccionario de variables de los datasets finales.

Atributo	Dataset	Descripción y cálculo
`ms`	R, S	Robot al que pertenece la observación: VMS 1, VMS 2 o VMS 3
`bloque_tiempo`	R, S	Inicio del intervalo de 30 minutos: `hora_inicio` redondeada hacia abajo. En la serie también se generan intervalos sin registros
`total_ordenios`	S	Ordeños iniciados en el robot durante el bloque, incluidos los de 0 kg; 0 si no hubo registros
`produccion_promedio`	R, S	Promedio de `produccion_kg` de los ordeños iniciados en el bloque, incluidos los de 0 kg. En la serie es nulo si no hubo ordeños
`duracion_total_min`	S	Suma de `duracion_min`. Puede superar 30 min porque cada ordeño completo se asigna al bloque donde inicia
`patadas_totales`	R, S	Suma de `patada_cant`. Un ordeño puede aportar más de una incidencia; no es el número de vacas con patadas
`desviaciones_leche_totales`	R, S	Suma de `desviacion_leche`: 1 si el destino es distinto de Tanque y 0 si es Tanque. Los destinos nulos no cuentan como desviación
`ordenios_con_lavado`	R, S	Suma de `programa_lavado`, codificado como 1 para “Local Aclarado” y 0 en otro caso
`pct_primer_parto`	R, S	Promedio de `es_primer_parto` entre los registros con grupo conocido, de 0 a 1
`pct_fresca`, `pct_alta`, `pct_baja`, `pct_extendida`	R, S	Proporción de ordeños en cada etapa de lactancia: promedio de `es_fresca`, `es_alta`, `es_baja` y `es_extendida` entre los registros con etapa conocida, de 0 a 1
`hubo_ordenios`	S	1 si hay ordeños registrados y 0 en los intervalos añadidos sin registros. Sustituye la necesidad de `bloque_artificial`
`pct_ocupacion_robot`	S	`duracion_total_min` entre 30 min, con máximo de 1. Es una aproximación, no una medición exacta de ocupación por solapamiento
`hubo_lavado`	R, S	1 si `ordenios_con_lavado` es mayor que 0. No representa un registro independiente de todos los lavados
`ordenios_otros_robots`	S	Suma de `total_ordenios` de todos los robots en el bloque menos los del robot de la fila. Puede ser mayor que 0 aunque `hubo_ordenios` sea 0
`hora`	R, S	Hora del día en que comienza el bloque (0 a 23)
`dia_semana`	R, S	Día de la semana del bloque: 0 es lunes y 6 es domingo
`temporada`	R, S	Dic a feb, invierno; mar a may, primavera; jun a ago, verano; sep a nov, otoño
`min_desde_alimento`	R, S	Minutos desde el último horario programado de alimentación (7:30 o 14:30 h), incluido el día anterior cuando corresponde. No mide el tiempo desde el último ordeño
`vacas_activas_dia`	R, S	Vacas distintas con ordeños registrados ese día en los tres robots. Se repite en los bloques del día y no equivale al inventario total del hato

Atributo	Dataset	Descripción y cálculo
ocupacion_bloque_anterior	R	pct_ocupacion_robot del bloque previo del mismo robot, con rezago de un bloque sobre la malla completa (0 a 1)
ordenios_bloque_anterior	R	total_ordenios del bloque previo de 30 min; vale 0 si ese bloque no tuvo registros
pct_cola_bloque_anterior	R	pct_posible_cola del bloque previo del mismo robot; 0 si no hubo ordeños en ese intervalo
sin_etapa	R, S	1 si pct_fresca era nulo antes del relleno y 0 en otro caso. Las cinco proporciones faltantes se sustituyen por 0
pct_posible_cola	R, S	**Variable objetivo.** Promedio de posible_cola por robot y bloque; posible_cola vale 1 si el hueco hasta el siguiente ordeño del robot es de 0 a 2 min (0 a 1). En la serie vale 0 en los bloques sin ordeños

7.5 Bloques sin ordeños

Un bloque con hubo_ordenios igual a 0 es un intervalo añadido porque no hay registros de inicio de ordeño. La construcción interpreta esa ausencia como falta de ordeños registrados. Los ceros asignados a cola y ocupación son una convención del dataset, no mediciones independientes: no descartan una interrupción del registro ni un ordeño iniciado en el bloque previo.

Cuadro 15: Valores en un bloque sin ordeños (dataset de serie de tiempo).

Variables	Valor
hubo_ordenios y total_ordenios	0
duracion_total_min y pct_ocupacion_robot	0
patadas_totales y desviaciones_leche_totales	0
ordenios_con_lavado y hubo_lavado	0
pct_posible_cola	0, asignado por la construcción del dataset
produccion_promedio	Nulo, porque no hay ordeños que promediar
Las cinco proporciones de lactancia	0; sin_etapa vale 1
ordenios_otros_robots	Se calcula con los demás robots; puede ser mayor que 0
vacas_activas_dia	Se conserva el conteo de vacas registradas en todo el día
hora, dia_semana, temporada y min_desde_alimento	Se recalculan a partir de la fecha y hora del bloque
ms y bloque_tiempo	Identifican el robot y el intervalo correspondiente

7.6 Conclusiones

Los dos datasets responden a dos usos distintos. El de regresión, sin variables mecánicas del mismo bloque, sirve para estudiar qué entradas se asocian con la posible cola sin que la ocupación domine el ajuste. El de serie de tiempo, con intervalos continuos y todas las variables de actividad, sirve para analizar secuencias y pronosticar. Al compartir la llave `ms` y `bloque_tiempo` y la variable objetivo, los resultados de ambos son comparables. En el de serie de tiempo hay que tener presente que el 26.57 % de las filas son bloques sin ordeños, con valores asignados por convención.

---

8. Conclusiones generales

La fase de Data Preparation convirtió los datos del CAETEC en dos datasets listos para modelar: uno de regresión y otro de serie de tiempo. Se eligió como nivel de análisis el bloque de 30 minutos por robot, porque a nivel ordeño ninguna variable explicaba la cola. La limpieza corrigió los errores de integridad con un costo mínimo de registros (6 ordeños de 278,767) y conservó con banderas los eventos reales atípicos. Se construyeron atributos temporales, de ocupación, de lactancia y del bloque anterior, y se excluyeron las variables que filtraban información del objetivo.

Se mantienen las limitaciones identificadas en Data Understanding: la cola se mide de forma indirecta con el tiempo libre entre ordeños, el historial solo incluye a las vacas actuales, lo que puede subestimar las colas en los primeros años, y el ciclo de lactancia se infiere a partir de los periodos sin ordeño.

El siguiente paso es la fase de modelado. El dataset de regresión se usará para ajustar modelos de `pct_posible_cola` con una validación temporal de 5 folds, y el de serie de tiempo para estudiar secuencias y pronosticar, construyendo los rezagos según la ventana elegida.