Supuestos del modelado

1. Supuestos iniciales y de calidad/formato de los datos

En las fases iniciales del proyecto y bajo la metodología CRISP-DM, declaramos diversos supuestos contextuales y de calidad sobre los datos. Respecto a los requerimientos de formato para las técnicas de modelado seleccionadas, asumimos que los datos contendrían series continuas y completas. Sin embargo, la implementación de modelos secuenciales como LSTM, GRU y ARIMA/SARIMA exige una estricta continuidad temporal sin bloques vacíos para estructurar adecuadamente las secuencias de entrada y evitar distorsiones en los patrones temporales de las predicciones.

Negocio

Mientras que los supuestos contextuales, se tenía entendido que las vacas son alimentadas dos veces al día; sus actividades diarias se realizan a lo largo del día sin horarios predefinidos, dándoles libertad de descansar, comer y ordeñarse cuando tengan la necesidad. Igual se tenía la hipótesis que los ordeños de las vacas disminuirían en la noche, esto por algunos artículos de investigación que mencionaban aspectos similares, o que la producción de las vacas disminuía en invierno, mencionando una posible relación a días más cortos o temperatura.

Datos

En primer lugar pensábamos que iba a haber una mayor tendencia de ordeño durante el día que durante la noche. Y en cuanto a calidad de los datos asumimos que cada archivo decía la producción de la leche, pezones y datos de ordeño por cada vaca durante el tiempo.

En la fase de entendimiento de datos y preparación igual se encontró algunos aspectos que deben de tener considerados, como la ausencia de bloques de tiempo debido a sucesos atípicos.

2. Comparación y consistencia con los hallazgos de la Descripción de Datos

Al contrastar los supuestos con lo documentado en el Reporte de descripción de los datos y en la exploración inicial, se encontraron inconsistencias importantes. Aunque la fuente principal contempla más de 278,000 registros de ordeño en 201 vacas, se identificaron problemas de calidad como la presencia de un 3.05% de horas sin actividad simultánea en los

tres robots. Estos paros corresponden a anomalías operativas (ej., cortes de energía, o mantenimiento de la máquina) y no a comportamiento natural del ganado. Adicionalmente, se invalidó la hipótesis inicial de mayor flujo diurno: la exploración demostró que se mantienen ordeños continuos en la noche, con valles a las 4:00 h y 20:00 h y picos significativos entre las 22:00 h y la 1:00 h, 6:00 h y 10:00 y entre las 14:00h y 18:00 h.

3. Estado de los datos

Por el momento, los datos con los que se cuenta han sido preparados para empezar con la fase del modelado, contando con dos datasets diferentes, uno listo para los modelos secuenciales y otro para el categórico. Esto porque pensamos dividir fuerzas y tratar de poder predecir la existencia de una cola mediante los datos y el poder predecir cuándo ocurrirá la siguiente cola dado el historial de ordeño de las vacas por bloque.

Se mantiene abierta la posibilidad de volver a la preparación de datos en el supuesto de que los modelos no tengan los resultados esperados, y por si algún modelo puede verse beneficiado por la inclusión de consumo de las vacas. Esta información no se insertó en la primera iteración debido a que una gran cantidad de registros carecen de este parámetro, y optamos por tener mayor cantidad de registros, pese la pérdida de un campo informativo.